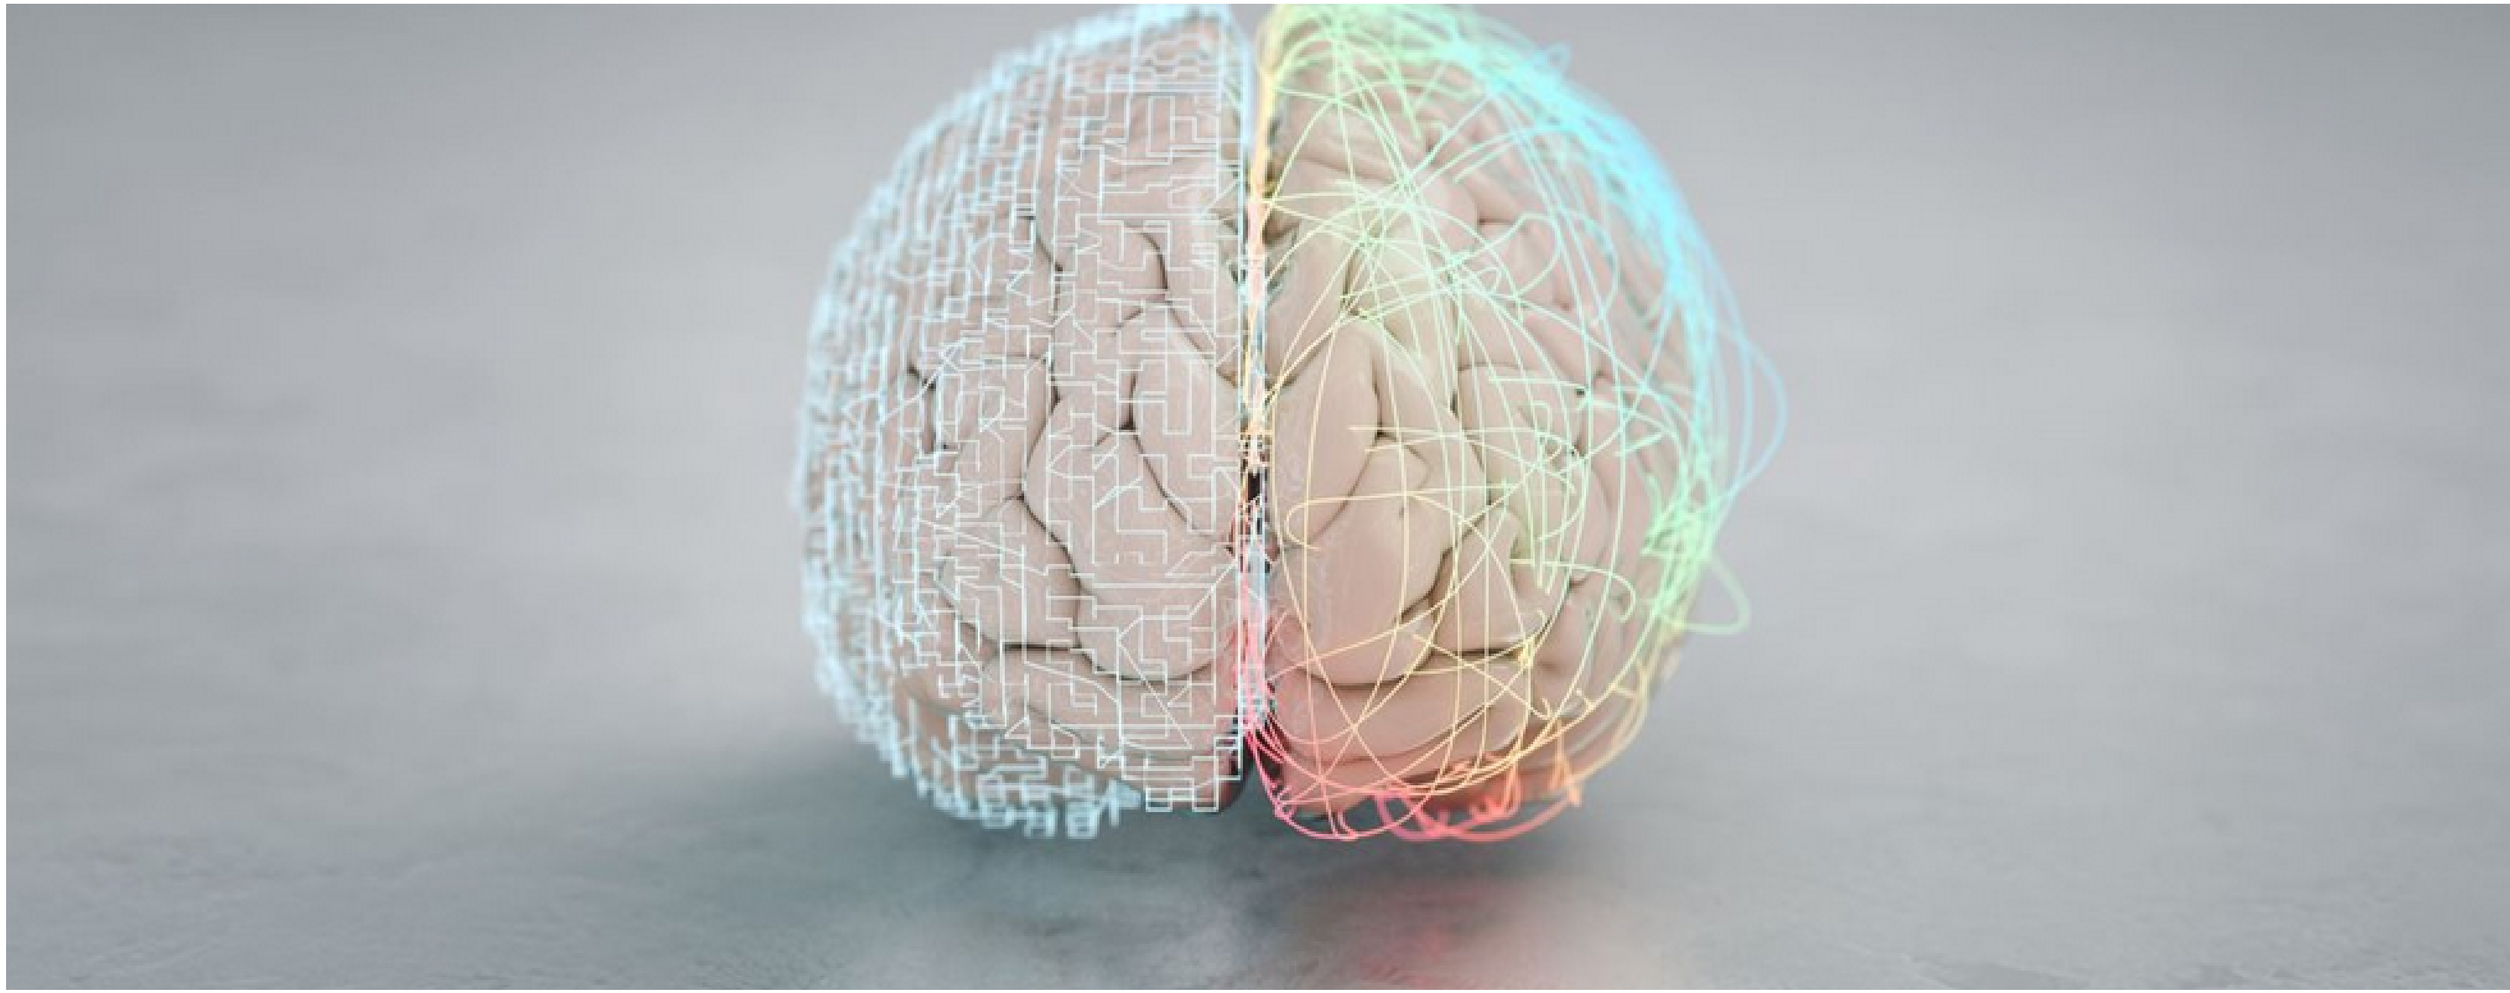


Aprendizado Supervisionado

Aula 7: Naive Bayes

Notas da P1

Naive Bayes

Por que utilizar outro método?

1. Quando há uma separação substancial entre as duas classes, as estimativas dos parâmetros do modelo de regressão logística são surpreendentemente instáveis.

2. Se a distribuição dos preditores (X) é aproximadamente normal em cada uma das classes e o tamanho da amostra é pequeno, então existem outras abordagens que podem ser mais precisas do que a regressão logística.

3. Esses métodos podem ser naturalmente estendidos para o caso de mais de duas classes de resposta. No caso de mais de duas classes de resposta, também podemos usar a regressão logística multinomial.

O que é Naive Bayes?

- O *Naive Bayes* é uma técnica de classificação que se baseia no Teorema de Bayes, com a suposição de que todas as características que predizem a resposta são **independentes** entre si.

- Calcula a probabilidade de cada classe e, em seguida, escolhe aquela com a **maior probabilidade**.

O que é Naive Bayes?

- Tem sido usado com sucesso para muitos propósitos, mas funciona particularmente bem em problemas de processamento de linguagem natural (NLP).

- O Teorema de *Bayes* descreve a probabilidade de um evento, com base no conhecimento prévio (a priori) de condições que podem estar relacionadas a esse evento.

Bayes in a nutshell

$$P(H|E) = \frac{P(E|H) * P(H)}{P(E)}$$

Por que "ingênuo"?

- O classificador *Naive Bayes* assume que as características que usamos para prever o alvo são independentes, i.e., não afetam umas às outras.

- Nos dados da vida real, frequentemente as características dependem umas das outras na determinação do alvo, isso é ignorado pelo classificador *Naive Bayes*.

- Embora a suposição de independência nunca seja correta em dados do mundo real, muitas vezes funciona bem na prática, por isso é chamado de "*Naive*" (ingênuo).

Matemática por detrás...

- Dado um vetor X = {x1, x2,..., xn} e uma classe resposta y, Bayes afirma que:

$$P(y|X) = \frac{P(X|y) * P(y)}{P(X)}$$

- Estamos interessados na probabilidade a posterior do evento. Usando a regra da cadeia podemos decompor a verossimilhança P(X|y):

$$P(X|y) = P(x_1, x_2, \ldots, x_n|y)$$

$$= P(x_1|x_2, \ldots, x_n, y) * P(x_2|x_3, \ldots, x_n, y) \ldots P(x_n|y)$$

Matemática por detrás...

- Mas, devido à suposição de independência condicional do Naive, as probabilidades condicionais são independentes entre si.

$$P(X|y) = P(x_1|y) * P(x_2|y) \ldots\ldots P(x_n|y)$$

- Então, pela independência condicional temos:

$$P(y|X) = \frac{P(x_1|y) * P(x_2|y) \ldots\ldots P(x_n|y) * P(y)}{P(x_1) * P(x_2) \ldots . P(x_n)}$$

Matemática por detrás...

- Como o denominador permanece constante para todos os valores, a probabilidade posterior pode então ser:

$$P(y|x_1, x_2, \ldots, x_n) \propto P(y) \prod_{i=1}^{n} P(x_i|y)$$

- O classificador *Naive Bayes* combina este modelo com uma **regra de decisão**. Uma regra comum é escolher a hipótese que é mais provável; isso é conhecido como a regra de decisão de máxima a posteriori ou regra MAP.

$$y = argmax_y P(y) \prod_{i=1}^{n} P(x_i|y)$$

Exemplo prático!

- Vamos classificar um conjunto de e-mails como Spam ou Não-Spam

- O conjunto de dados tem 15 e-mails classificados como **Não Spam** e 10 e-mails classificados como **Spam**.

- **ATENÇÃO**: "stop words" como "o", "a", "em", "de", "é", foram previamente removidas do texto (pré-processamento); o mesmo se aplica para números, caracteres especiais e pontuações

	NaoSpam	Spam
Caro	8	3
Visita	2	6
Intimação	5	2
Link	2	7
Amigo	6	1
Olá	5	4
Desconto	0	8
Dinheiro	1	7
Clique	2	9
Janta	3	0
Total Palavras	34	47

Exemplo prático!

- Visualizando algumas probabilidades:
  - P(Caro|**Nao Spam**) = 8/34
  - P(Visita|**Nao Spam**) = 2/34
  - P(Caro|**Spam**) = 3/47
  - P(Visita|**Spam**) = 6/47

E assim por diante...

	NaoSpam	Spam
Caro	8	3
Visita	2	6
Intimação	5	2
Link	2	7
Amigo	6	1
Olá	5	4
Desconto	0	8
Dinheiro	1	7
Clique	2	9
Janta	3	0
Total Palavras	34	47

Exemplo prático!

- Vamos agora imaginar o seguinte texto recebido:

"Olá amigo"

Usando teorema de Bayes:

$$P(NaoSpam|Ola\ Amigo) = \frac{P(Ola\ Amigo|NaoSpam) \cdot P(NaoSpam)}{P(Ola\ Amigo)}$$

	NaoSpam	Spam
Caro	8	3
Visita	2	6
Intimação	5	2
Link	2	7
Amigo	6	1
Olá	5	4
Desconto	0	8
Dinheiro	1	7
Clique	2	9
Janta	3	0
Total Palavras	34	47

Exemplo prático!

é o mesmo para todas as classes (Spam ou NotSpam)

Ignorar o denominador é válido quando estamos apenas comparando qual classe é mais provável (classificação).

- Ignorando o denominador:
P(Ola amigo|NaoSpam) = P(Ola amigo|NaoSpam) . P(NaoSpam)

Só que"Olá Amigo", tanto para NaoSpam quanto Spam, seriam zeros, pois não temos essa expressão completa (apenas fragmentos de palavras).

- Naive Bayes assume que "as características que usamos para prever a resposta são independentes".

	NaoSpam	Spam
Caro	8	3
Visita	2	6
Intimação	5	2
Link	2	7
Amigo	6	1
Olá	5	4
Desconto	0	8
Dinheiro	1	7
Clique	2	9
Janta	3	0
Total Palavras	34	47

Exemplo prático!

- Naive Bayes assume que "*as características que usamos para prever a resposta são independentes*".

$$P(Ola\ Amigo|NaoSpam) = P(Ola|NaoSpam) \cdot P(Amigo|NaoSpam)$$

$$P(NaoSpam|Ola\ Amigo) = P(Ola|NaoSpam) \cdot P(Amigo|NaoSpam) \cdot P(NaoSpam)$$

$$\rightarrow P(NaoSpam|Ola\ Amigo) = \frac{5}{34} \cdot \frac{6}{34} \cdot \frac{15}{25} = 0.0155$$

	NaoSpam	Spam
Caro	8	3
Visita	2	6
Intimação	5	2
Link	2	7
Amigo	6	1
Olá	5	4
Desconto	0	8
Dinheiro	1	7
Clique	2	9
Janta	3	0
Total Palavras	34	47

Exemplo prático!

- Naive Bayes assume que "as características que usamos para prever a resposta são independentes".

$$\rightarrow P(Spam|Ola\ Amigo) = \frac{4}{47} \cdot \frac{1}{47} \cdot \frac{10}{25} = 0.00072$$

$$\therefore \text{NOTSPAM}$$

	NaoSpam	Spam
Caro	8	3
Visita	2	6
Intimação	5	2
Link	2	7
Amigo	6	1
Olá	5	4
Desconto	0	8
Dinheiro	1	7
Clique	2	9
Janta	3	0
Total Palavras	34	47

Exemplo prático!

- Façam o mesmo para a expressão:

"Caro visita janta dinheiro dinheiro dinheiro"

Certamente um SPAM, não?

	NaoSpam	Spam
Caro	8	3
Visita	2	6
Intimação	5	2
Link	2	7
Amigo	6	1
Olá	5	4
Desconto	0	8
Dinheiro	1	7
Clique	2	9
Janta	3	0
Total Palavras	34	47

Problema de Zero-Frequência

Pera!

Naive retornou que NÃO é um SPAM???

Isto ocorre pois a palavra "Janta" não está no conjunto marcado como Spam, logo todas as demais palavras não terão impacto.

Isso é conhecido como **problema de zero-frequência**

Cálculos para NãoSpam	Cálculos para Spam
$P(d \mid \text{NãoSpam}) = \frac{8}{34} \times \frac{2}{34} \times \frac{3}{34} \times \left(\frac{1}{34}\right)^3 = 3{,}107 \times 10^{-8}$ $P(\text{NãoSpam}) = 0{,}6$ $P(\text{NãoSpam})P(d \mid \text{NãoSpam}) = 1{,}864 \times 10^{-8}$	$P(d \mid \text{Spam}) = \frac{3}{47} \times \frac{6}{47} \times \frac{0}{47} \times \left(\frac{7}{47}\right)^3 = 0$ $P(\text{Spam}) = 0{,}4$ $P(\text{Spam})P(d \mid \text{Spam}) = 0$

	NaoSpam	Spam
Caro	8	3
Visita	2	6
Intimação	5	2
Link	2	7
Amigo	6	1
Olá	5	4
Desconto	0	8
Dinheiro	1	7
Clique	2	9
Janta	3	0
Total Palavras	34	47

Suavização de Laplace

- Para solucionar isso podemos usar **suavização de Laplace**

É uma técnica para suavizar dados categóricos.

Uma correção de pequena amostra, ou pseudo-contagem, será incorporada em cada estimativa de probabilidade. Assim, nenhuma probabilidade será zero. Isso é uma forma de regularizar o *Naive Bayes*.

Suavização de Laplace

Dada uma observação x=(x1,...,xd) de uma distribuição multinomial com N tentativas e vetor de parâmetros θ=(θ1,...,θd), uma versão "suavizada" dos dados fornece o estimador:

$$\hat{\theta} = \frac{x_i + \alpha}{N + \alpha d} \qquad (i = 1, \ldots, d)$$

onde a pseudo-contagem α > 0 é o parâmetro de suavização (α=0 corresponde a nenhuma suavização).

No nosso problema, podemos assumir:
α = 1 e d = 10 sendo "d" a quantidade de palavras únicas (distintas) no dataset

Resposta

P(NaoSpam|Caro visita...) = $0.7144 * 10^{-7}$

P(Spam|Caro visita...) = $1.672 * 10^{-7}$

P(Spam|Caro...) > P(NaoSpam)

Declarado corretamente!

Com suavização de Laplace ($\alpha = 1$)	$P(d \mid \text{NãoSpam}) = \frac{8+1}{34+10} \times \frac{2+1}{34+10} \times \frac{3+1}{34+10} \times \left(\frac{1+1}{34+10}\right)^3 = \frac{9}{44} \times \frac{3}{44} \times \frac{4}{44} \times \left(\frac{2}{44}\right)^3 = 1{,}191 \times 10^{-7}$ $P(\text{NãoSpam}) = 0{,}6$ $P(\text{NãoSpam})P(d \mid \text{NãoSpam}) = 7{,}147 \times 10^{-8}$	$P(d \mid \text{Spam}) = \frac{3+1}{47+10} \times \frac{6+1}{47+10} \times \frac{0+1}{47+10} \times \left(\frac{7+1}{47+10}\right)^3 = \frac{4}{57} \times \frac{7}{57} \times \frac{1}{57} \times \left(\frac{8}{57}\right)^3 = 4{,}180 \times 10^{-7}$ $P(\text{Spam}) = 0{,}4$ $P(\text{Spam})P(d \mid \text{Spam}) = 1{,}672 \times 10^{-7}$
Posterior (sem Laplace) $P(\text{NãoSpam} \mid d) = \frac{1{,}864 \times 10^{-8}}{1{,}864 \times 10^{-8} + 0} = 1\ (100\%)$ $P(\text{Spam} \mid d) = 0$ **Classificação: NãoSpam**	**Posterior (com Laplace)** $P(\text{NãoSpam} \mid d) = \frac{7{,}147 \times 10^{-8}}{7{,}147 \times 10^{-8} + 1{,}672 \times 10^{-7}} = 0{,}299\ (29{,}9\%)$ $P(\text{Spam} \mid d) = \frac{1{,}672 \times 10^{-7}}{7{,}147 \times 10^{-8} + 1{,}672 \times 10^{-7}} = 0{,}701\ (70{,}1\%)$ **Classificação: Spam**	

Tipos de classificadores NB

- **Multinomial:**

Os vetores de características representam as frequências com que certos eventos são gerados por uma distribuição multinomial.
Exemplo: contagem de quantas vezes cada palavra ocorre em um documento.
Este é o modelo de evento tipicamente utilizado para classificação de documentos.

- **Bernoulli:**

Semelhante ao modelo multinomial, é popular em tarefas de classificação de documentos.
Utiliza características de ocorrência binária de termos (ou seja, se uma palavra ocorre no documento ou não) em vez de frequências de termos.

- **Gaussiano:**

Usado em classificação, assume que as características seguem uma distribuição normal.

Prós&Contras

- **Prós:**

- Exige uma quantidade pequena de dados de treinamento (menos custoso).
- Lida com dados contínuos e discretos, e não é sensível a características irrelevantes.
- Muito simples, rápido e fácil de implementar.
- Pode ser usado tanto para problemas de classificação binária quanto multiclasse.
- Altamente escalável, pois escala linearmente com o número de características preditoras e pontos de dados.
- Quando a suposição de independência condicional do Naive Bayes é verdadeira, ele converge mais rapidamente do que modelos discriminativos, como a regressão logística.

Prós&Contras

- **Contra**

- A suposição de preditores/características independentes.
  O Naive Bayes assume implicitamente que todos os atributos são mutuamente independentes, o que é quase **impossível** de encontrar em dados do mundo real.

- Se uma variável categórica tiver um valor que aparece no conjunto de dados de *teste*, mas não foi observado no conjunto de dados de *treino*, o modelo atribuirá a ela uma probabilidade **zero** e não conseguirá fazer uma previsão.
  Isso é o que chamamos de “problema da frequência zero”, e pode ser resolvido utilizando técnicas de suavização.

Atividade



From scratch
NB