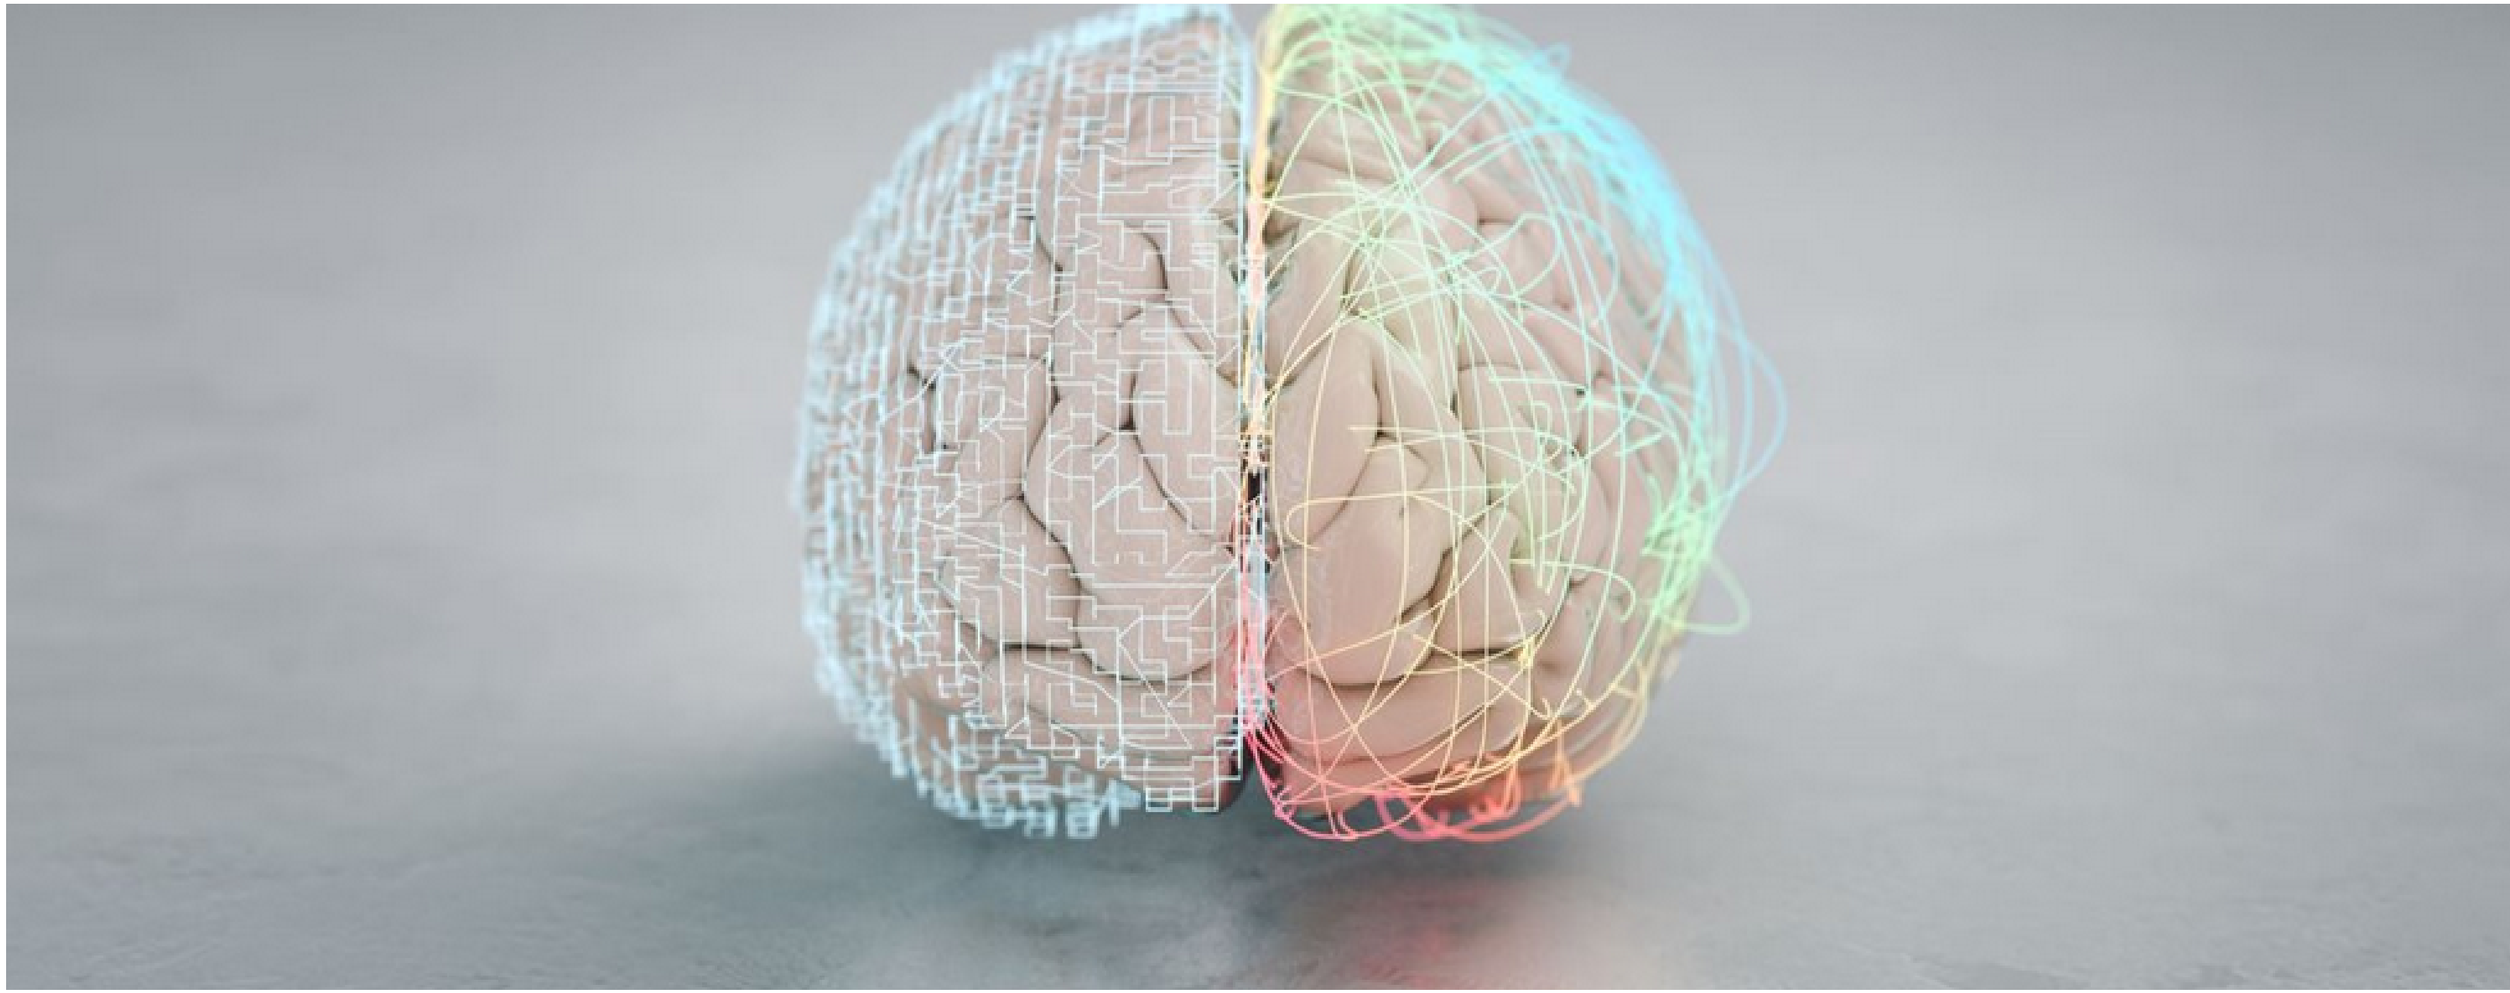


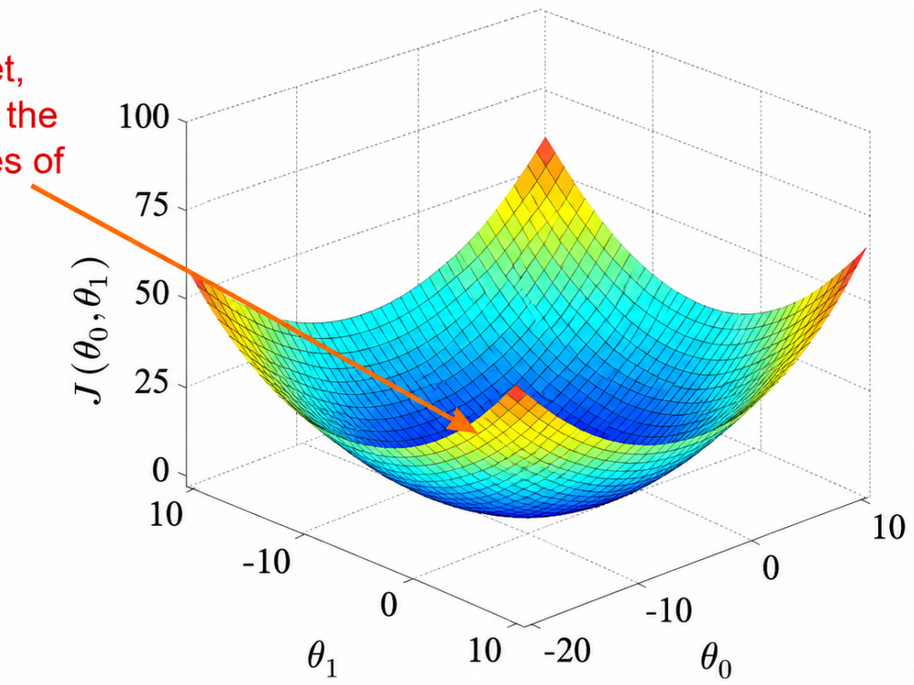
Aprendizado Supervisionado

Aula 5: Gradiente de descida estocástico (SGD) e Método dos mínimos quadrados (MMQ)

Função Custo (Objetivo)

Dado um *dataset*, nossa meta é obter um valor mínimo para a função

Given a dataset, our goal is find the minimum values of $J(\theta_0, \theta_1)$



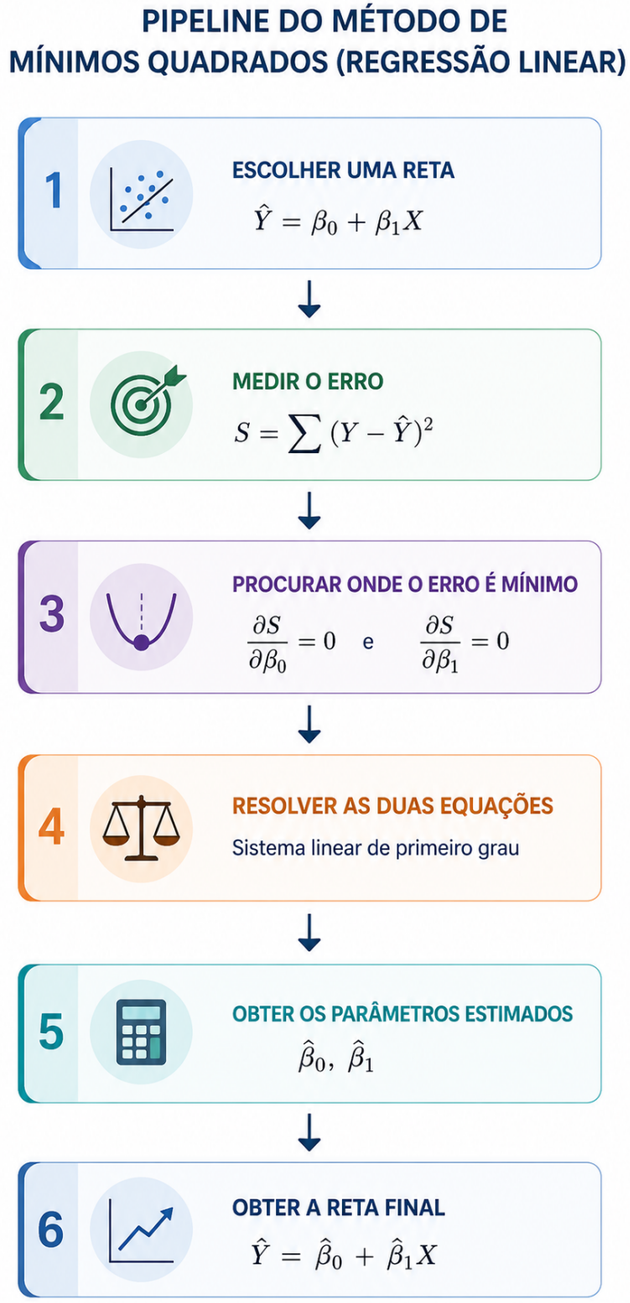
Função Custo (Objetivo)

“Derivamos a função de erro em relação aos parâmetros porque queremos encontrar o ponto em que pequenas alterações nesses parâmetros não conseguem mais reduzir o erro”

Como temos dois parâmetros, obtemos duas equações, cuja solução fornece a reta de menor erro



Exemplo de solução MMQ (OLS)



Gradiente de Descida Estocástico

ALGORITMO

1. Inicia com valores iniciais aos parâmetros.

2. Segue mudando os parâmetros para reduzir o erro da função custo, até que haja convergência em um mínimo

J is 0 or 1

Repeat until convergence {

$$Temp0 := \theta_0 - \alpha \cdot \frac{\partial}{\partial \theta_0} \cdot J(\theta_0, \theta_1)$$

$$Temp1 := \theta 1 - \alpha \cdot \frac{\partial}{\partial \theta_1} \cdot J(\theta_0, \theta_1)$$

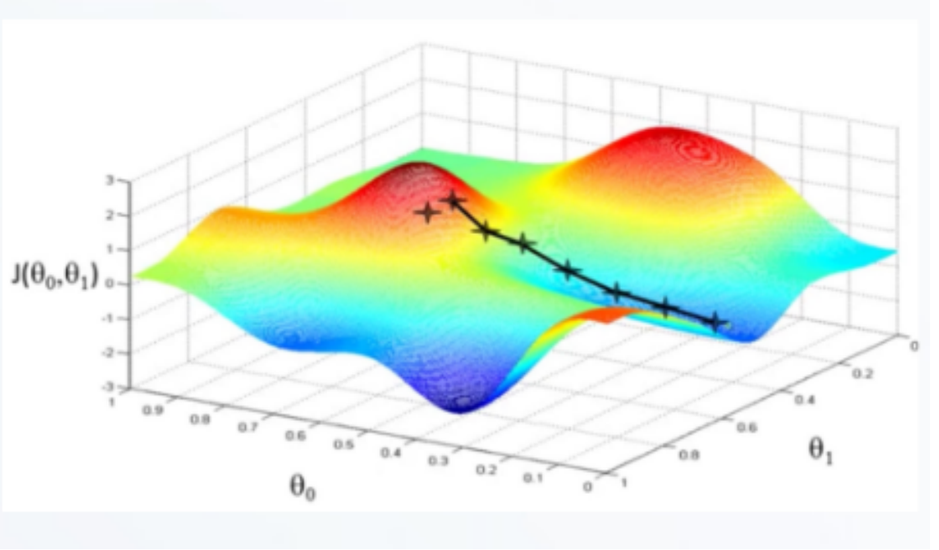
$$\theta_0 := Temp0$$

$$\theta_1 := Temp1$$

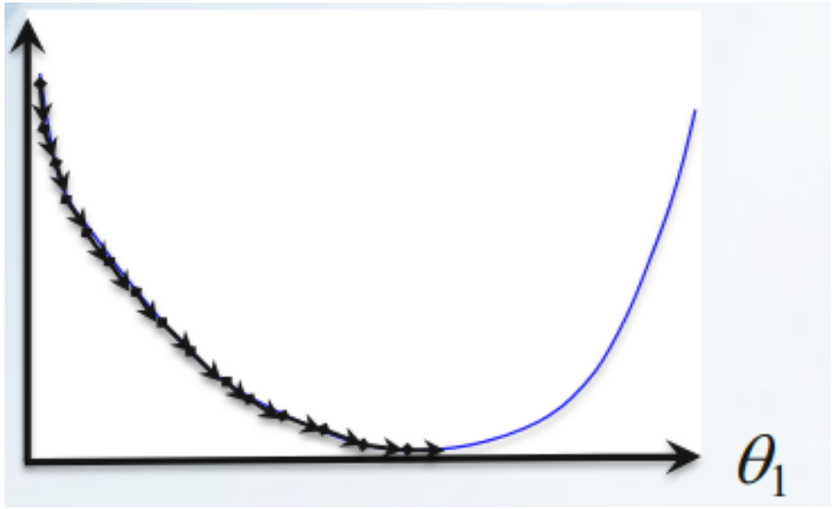
}

Learning Rate

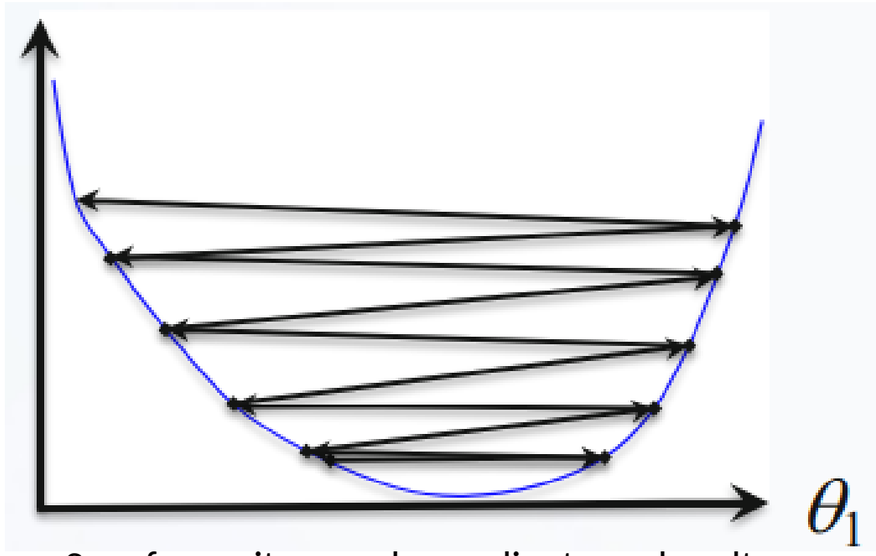
Partial Derivation



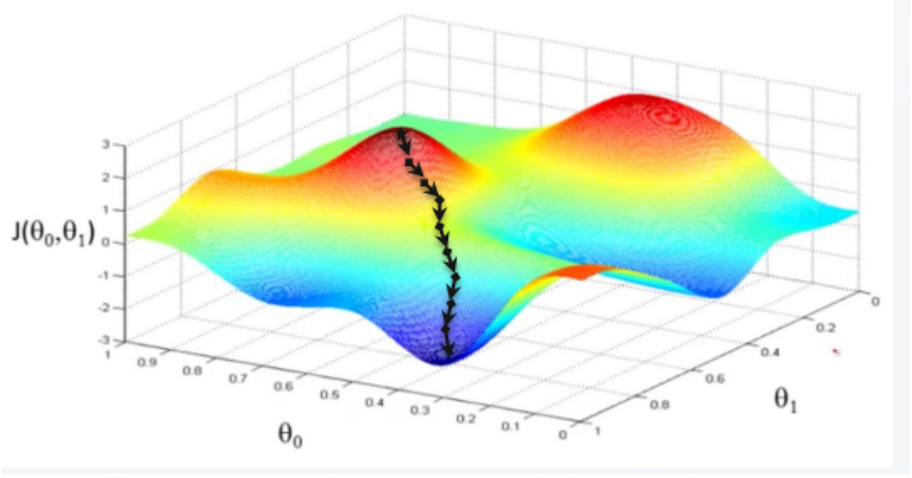
Problemáticas do SGD



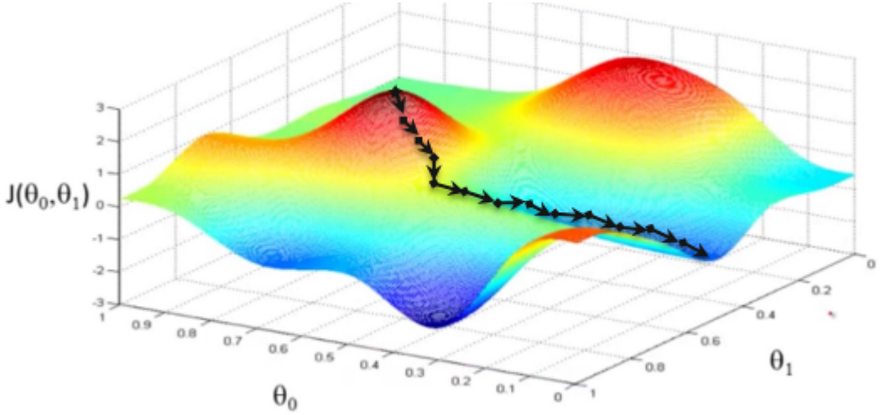
Se α for muito pequeno, gradiente pode ser muito demorado



Se α for muito grande, gradiente pode saltar o mínimo. Pode falhar para convergir ou simplesmente diverge



Pode convergir para um mínimo global



Pode convergir para um mínimo local

Gradiente de Descida Estocástico

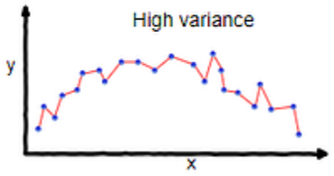


Interpretação
geométrica
da derivada
(dGeom.py)

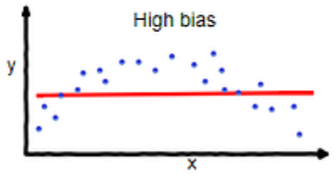
Regressão?



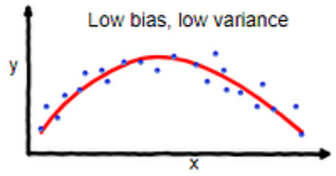
Regularizadores



overfitting



underfitting



Good balance

Como ver na prática?

Etapa de métricas do modelo após o treinamento (última etapa do KDD)

No *overfitting* o modelo pode "decorar" o ruído (*epsilon*)

Regularizadores

LASSO: *Least Absolute Shrinkage and Selection Operator (L1)*

- Quando há múltiplas features altamente correlacionadas, a regularização Lasso seleciona apenas uma dessas features e **zera os coeficientes** das outras, de forma a minimizar a penalização L1

Lasso (ou L1)

$$\mathrm{RSS}_{\mathrm{lasso}} = \sum_{i=1}^{n} \left[y_i - (\mathbf{w} \cdot \mathbf{x}_i + b) \right]^2, \boxed{+ \alpha \sum_{j=1}^{p} |w_j|}$$

regularização ℓ_1

Regularizadores

RIDGE: (L2)

- Faz com que o modelo penalize grandes coeficientes (reduz, mas mantém todos)
- Ideal para situações onde há muitas features relevantes mas correlacionadas (colinearidade), pois ela distribui o impacto entre as variáveis.

$$\mathrm{RSS}_{\mathrm{ridge}} = \sum_{i=1}^{n} \left[y_i - (\mathbf{w} \cdot \mathbf{x}_i + b) \right]^2 + \alpha \sum_{j=1}^{p} w_j^2$$

regularização ℓ_2

Regularizadores

Elastic Net:

Combina os termos de regularização de L1 e L2.

Obtemos o melhor dos dois mundos, porém temos que enfrentar o problema de determinar dois hiperparâmetros para obter soluções ótimas.

$$\mathrm{RSS}_{\mathrm{elasticnet}} = \sum_{i=1}^{n} \left[y_i - (\mathbf{w} \cdot \mathbf{x}_i + b) \right]^2 + \alpha_1 \sum_{j=1}^{p} |w_j| + \alpha_2 \sum_{j=1}^{p} w_j^2$$

Regularizadores

Característica	Ridge (L2)	Lasso (L1)
Coeficientes Zeros	Não zera coeficientes	Pode forçar coeficientes a zero
Colinearidade	Distribui peso entre variáveis	Seleciona uma variável e zera as outras
Seleção de Variáveis	Mantém todas as variáveis no modelo	Faz seleção de variáveis (coeficientes zero)
Uso	Ideal para quando temos colinearidade	Ideal para reduzir dimensionalidade e selecionar variáveis

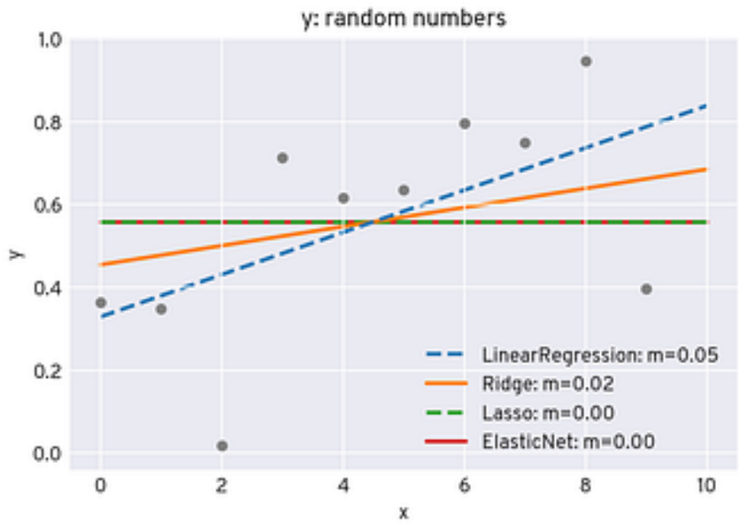
Regularizadores

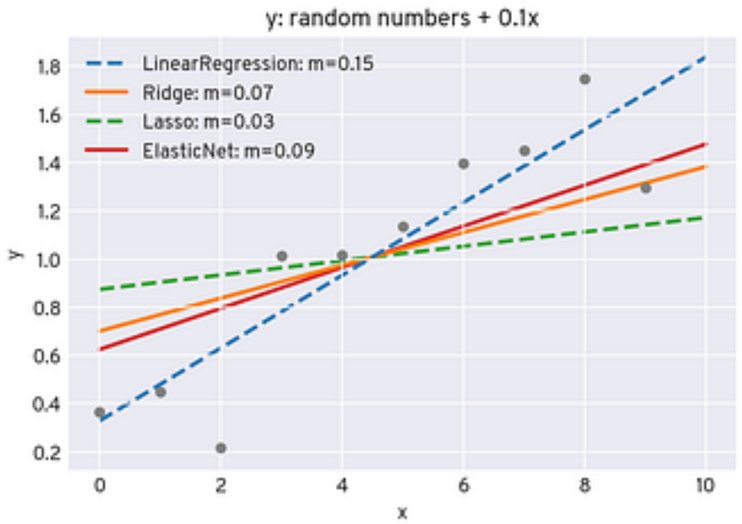
EM RESUMO:

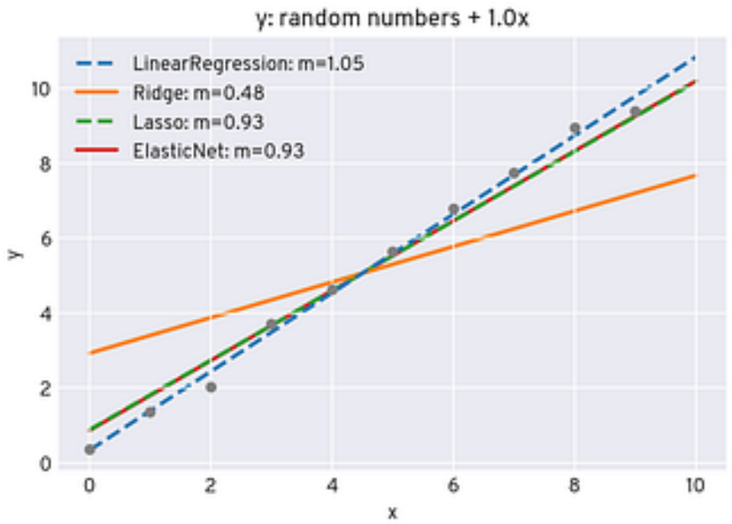
- A regressão Ridge é mais adequada quando todas as variáveis são importantes e há correlações entre elas.

- A regressão Lasso é usada quando queremos reduzir a complexidade do modelo eliminando variáveis irrelevantes.

Regularizadores





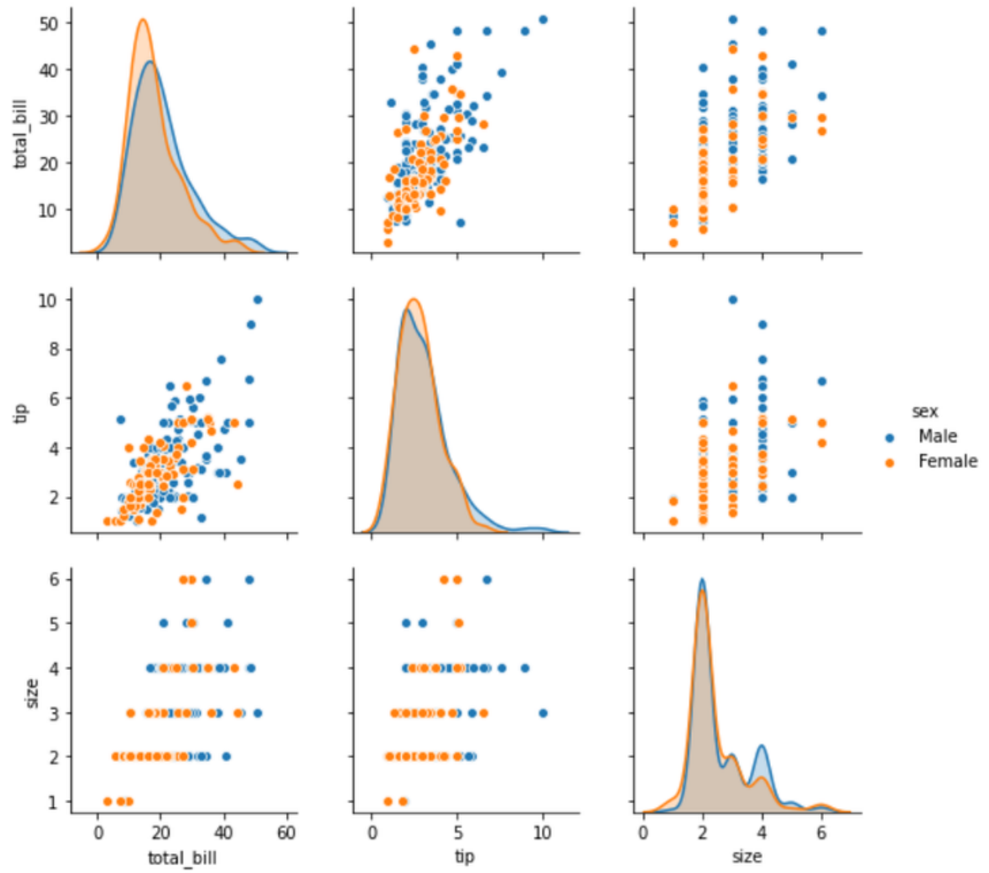


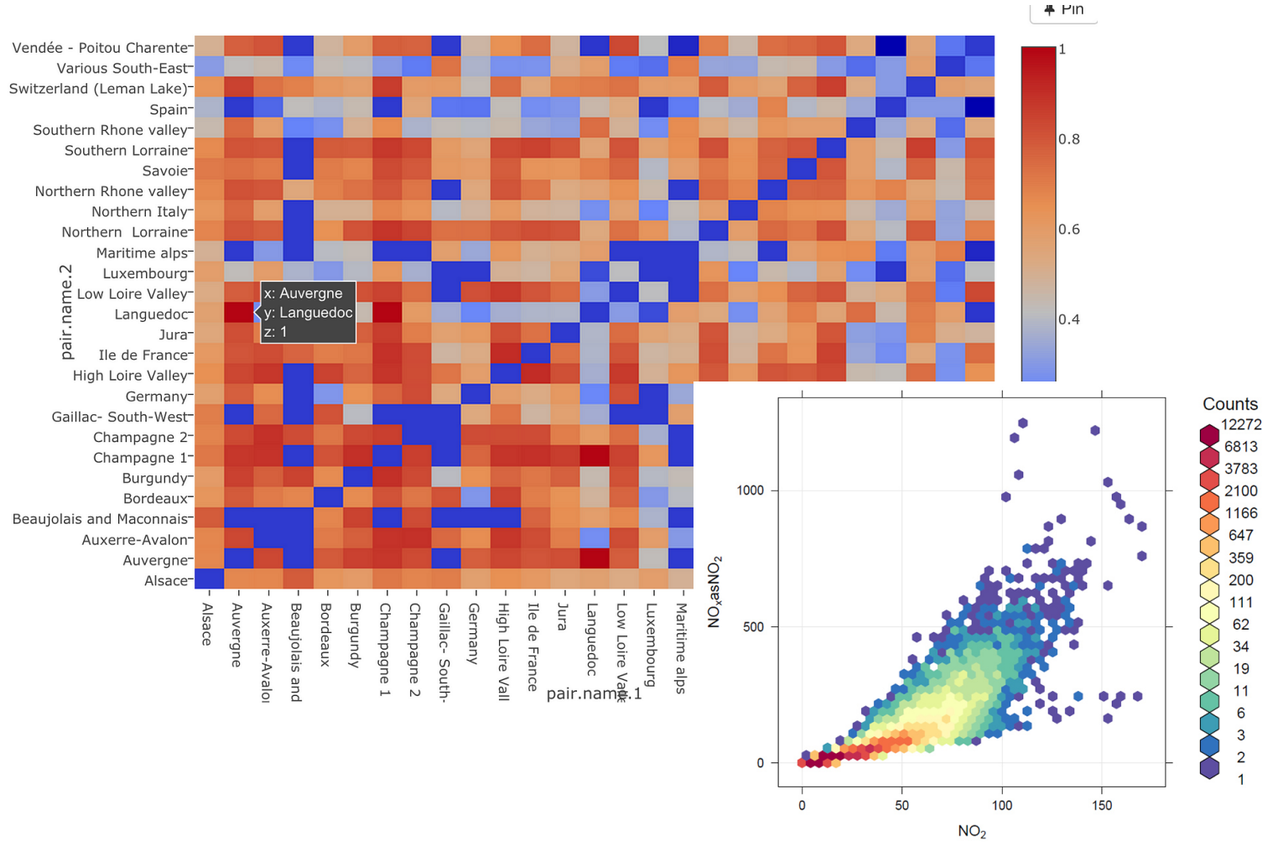
Regularizadores



Considerações Finais

- A relação entre as variáveis independentes e o valor esperado da variável dependente deve ser aproximadamente linear.
- Como descobrimos?

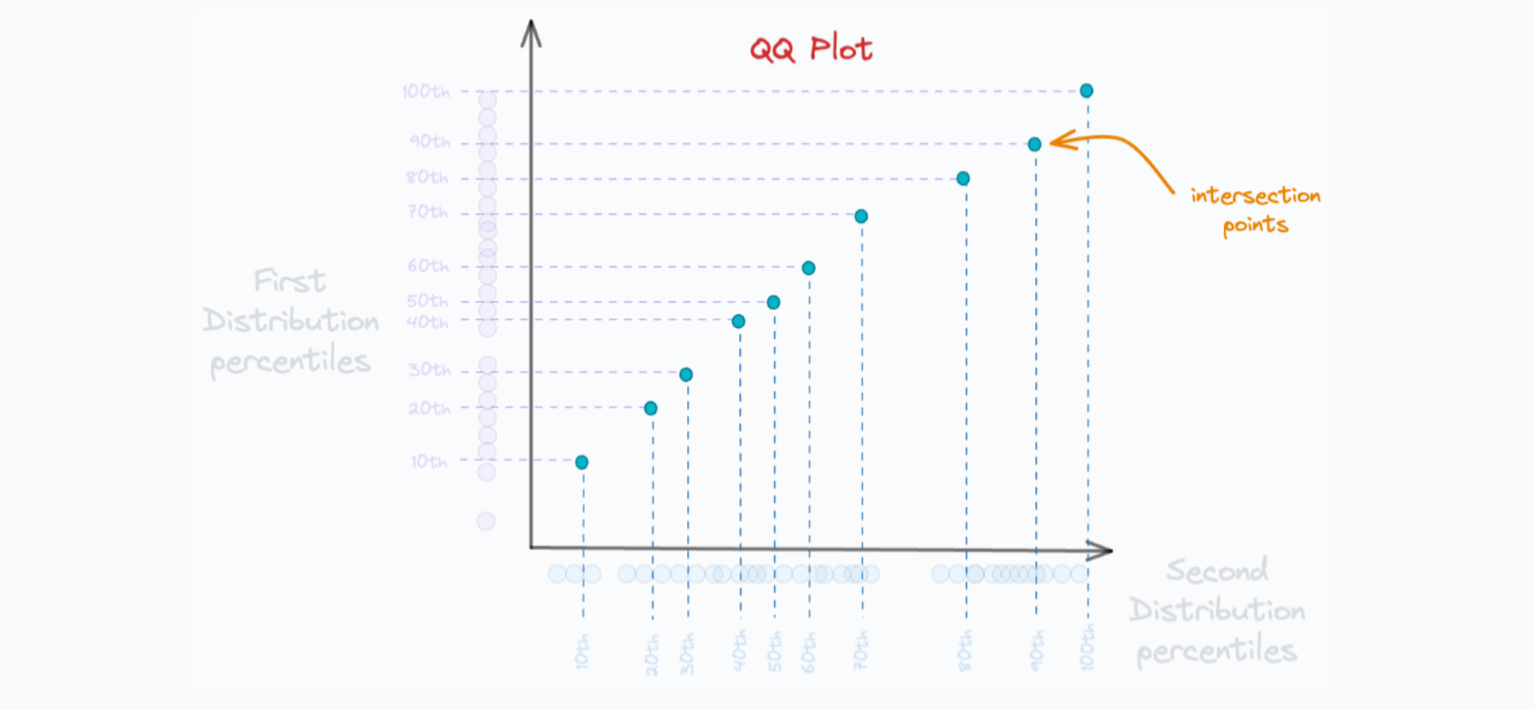




Considerações Finais

- Variáveis independentes devem ser linearmente relacionadas a var. Dependente. Como? EDA (*Heatmap, pairplot, scatter*, ...)

- Cada feature é normalmente distribuída (Q-Q plot, histograma...)



Considerações Finais

- Variáveis independentes devem ser linearmente relacionadas a var. Dependente. Como? EDA (*Heatmap, pairplot, scatter*, ...)

- Cada feature é normalmente distribuída (Q-Q plot, histograma...)

- Pouca ou nenhuma multicolinearidade (*Variance Inflaction Factor – VIF*)

Considerações Finais

- Variáveis independentes devem ser linearmente relacionadas a var. Dependente. Como? EDA (*Heatmap, pairplot, scatter*, ...)
- Cada feature é normalmente distribuída (Q-Q plot, histograma...)
- Pouca ou nenhuma multicolinearidade (*Variance Inflaction Factor – VIF*)
- Média residual é zero

Considerações Finais

- Variáveis independentes devem ser linearmente relacionadas a var. Dependente. Como? EDA (*Heatmap, pairplot, scatter*, ...)
- Cada feature é normalmente distribuída (Q-Q plot, histograma...)
- Pouca ou nenhuma multicolinearidade (*Variance Inflaction Factor – VIF*)
- Média residual é zero
- Resíduos devem ser normalmente distribuídos (Q-Q plot)

Considerações Finais

- Variáveis independentes devem ser linearmente relacionadas a var. Dependente. Como? EDA (*Heatmap, pairplot, scatter*, ...)
- Cada feature é normalmente distribuída (Q-Q plot, histograma...)
- Pouca ou nenhuma multicolinearidade (*Variance Inflaction Factor – VIF*)
- Média residual é zero
- Resíduos devem ser normalmente distribuídos (Q-Q plot)
- Variância do resíduo constante ao longo do eixo

Saída do Statsmodel

Comparação de modelos:
- **AIC** (Akaike Information Criterion): Mede a qualidade do modelo, penalizando o número de parâmetros no modelo para evitar *overfitting*

- **BIC** (Bayesian Information Criterion): Possui uma penalização mais severa ao número de parâmetros do modelo, particularmente quando o tamanho da amostra é grande.

  - Em ambos valores menores são preferíveis

- **R^2 Ajustado**: Penaliza a inclusão de variáveis irrelevantes. É uma métrica mais confiável para avaliar o ajuste do modelo, especialmente em modelos com múltiplas variáveis

Saída do Statsmodel

- O **Omnibus** e **Prob(Omnibus)** teste de normalidade dos resíduos.
- **Skewness** e **Kurtosis** são medidas da forma da distribuição dos resíduos.
- **Durbin-Watson** verifica a presença de autocorrelação nos resíduos.
- **Jarque-Bera** testa a adequação dos resíduos à normalidade.
- **Número de Condição** mede a estabilidade do modelo, especialmente em relação à multicolinearidade.

NOTA: Essa tabela não basta para validar todas as premissas da regressão linear. Ainda é muito útil verificar graficamente os resíduos, principalmente para linearidade e homocedasticidade.

Revisão



linear_regression.ipynb