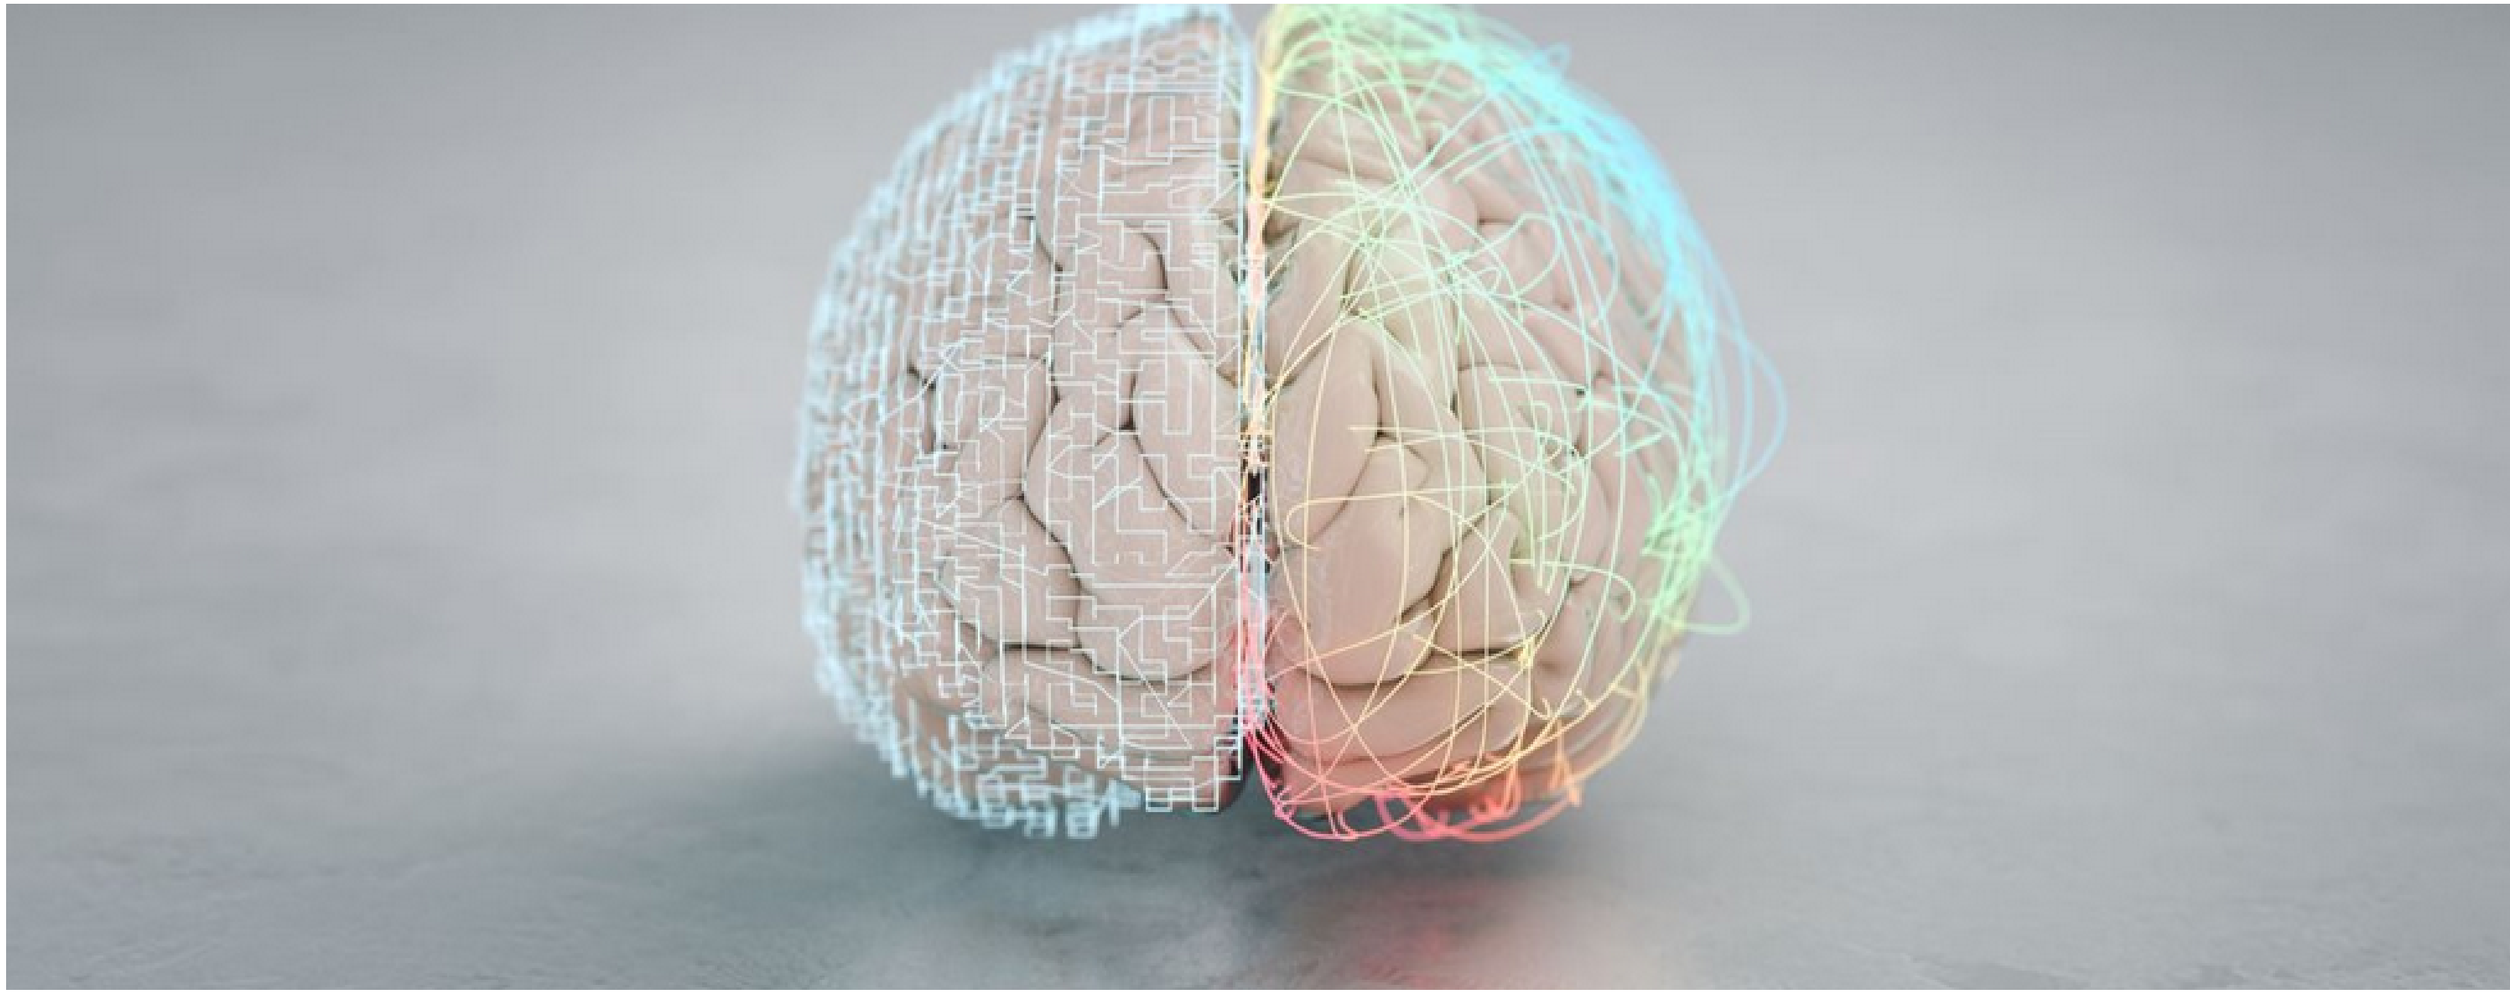


Aprendizado Supervisionado

Aula 3: Conceitos Gerais + Regressão Linear

Atividades



Fixação
Python

Hiperparâmetros

Many models have important parameters which cannot be directly estimated from the data. For example, in the K-nearest neighbor classification model … This type of model parameter is referred to as a tuning parameter because there is no analytical formula available to calculate an appropriate value.

— Page 64-65, Applied Predictive Modeling, 2013

Se você especifica um parâmetro manualmente, então certamente esse parâmetro é um hiperparâmetro

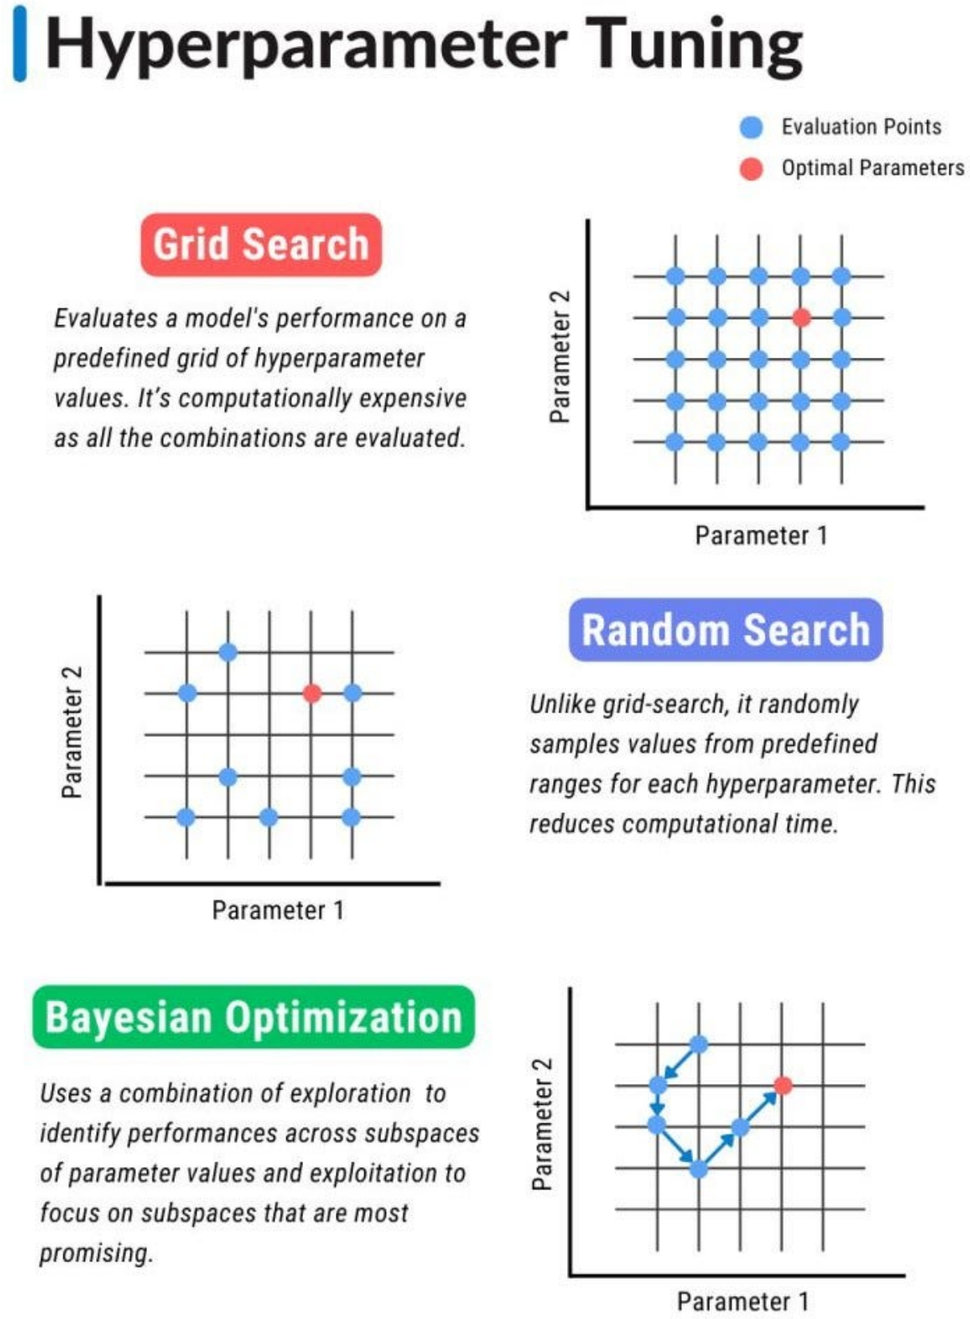
Fine-tuning

Condição para alcançar o máximo desempenho.

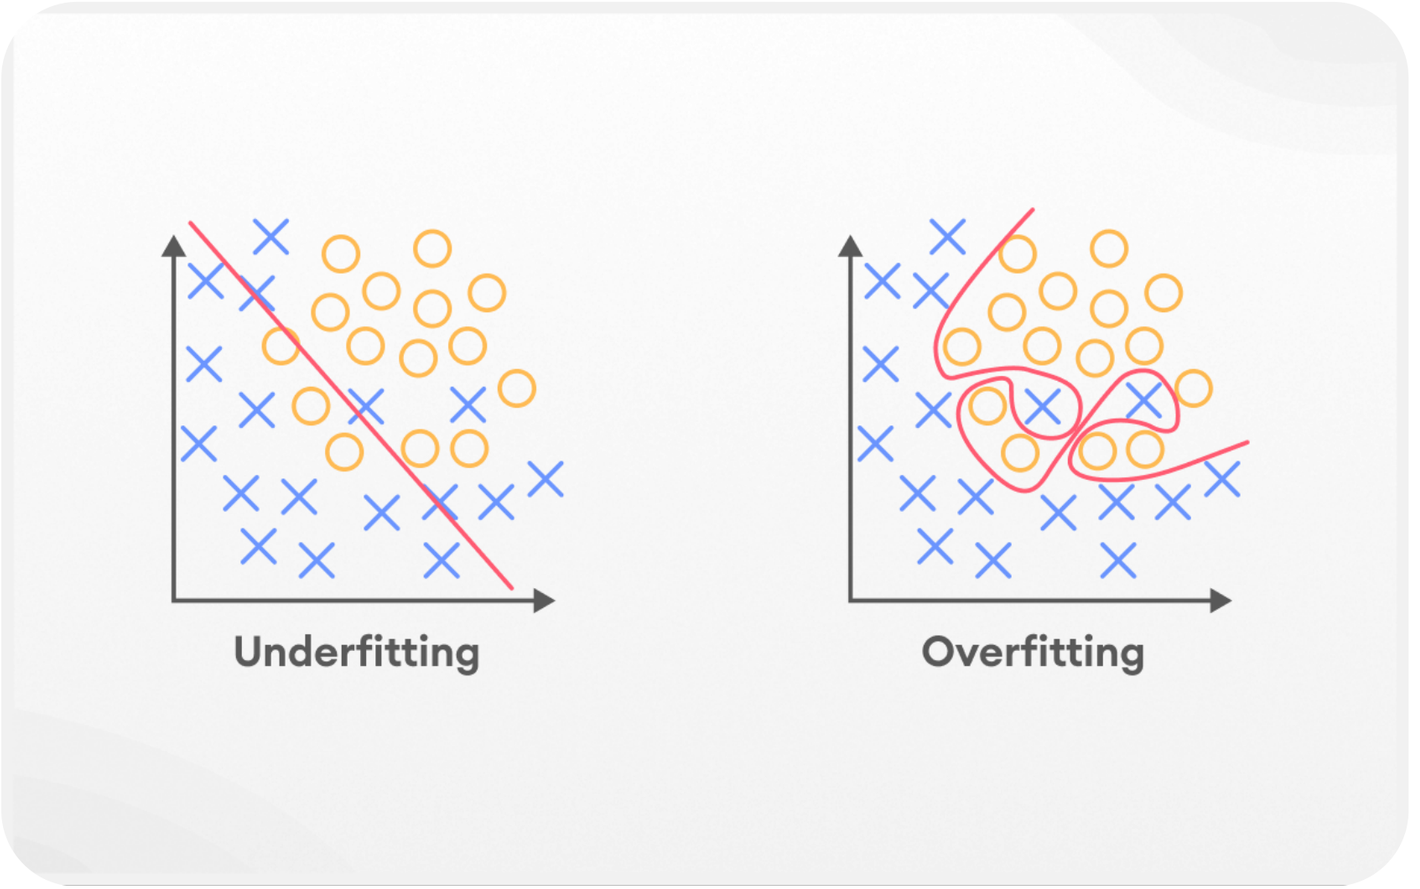
Uso da validação cruzada

Métodos:

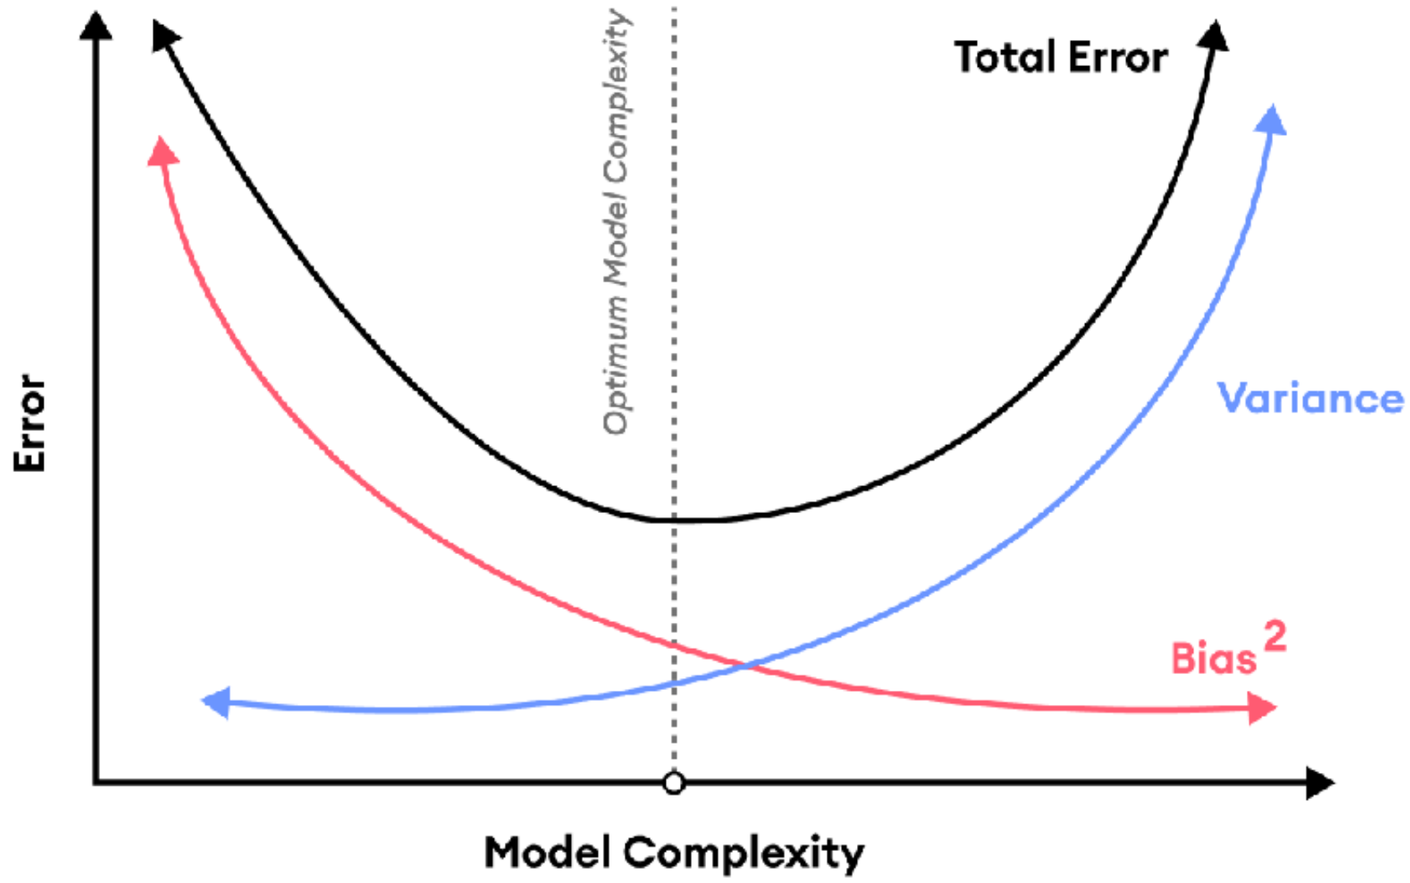
- Grid
- Random
- Bayesian



Overfitting/Underfitting

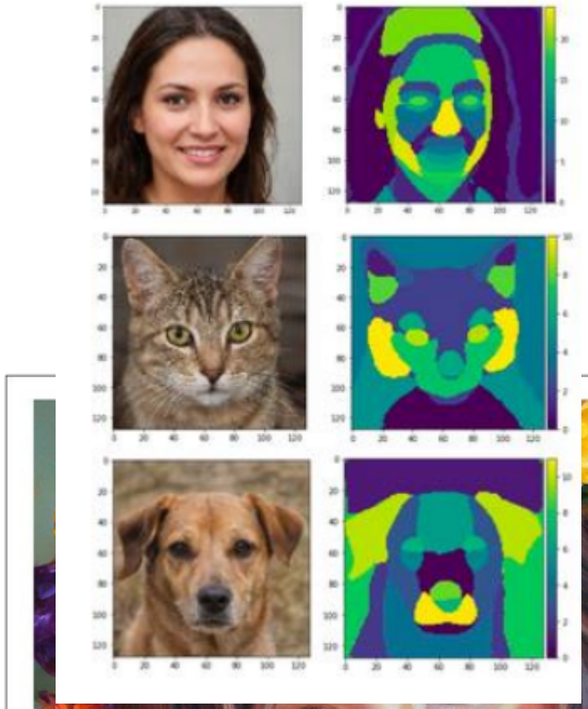


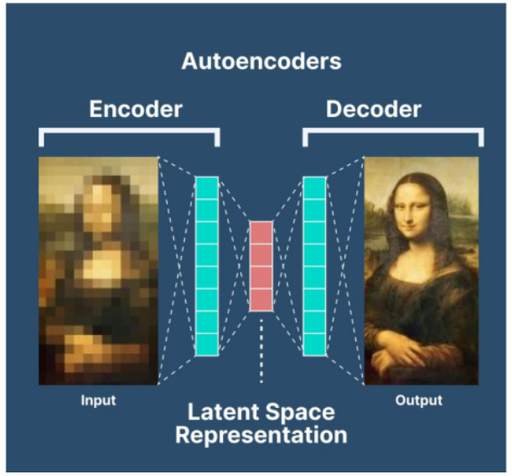
Decomposição do erro (bias-variância *tradeoff*)

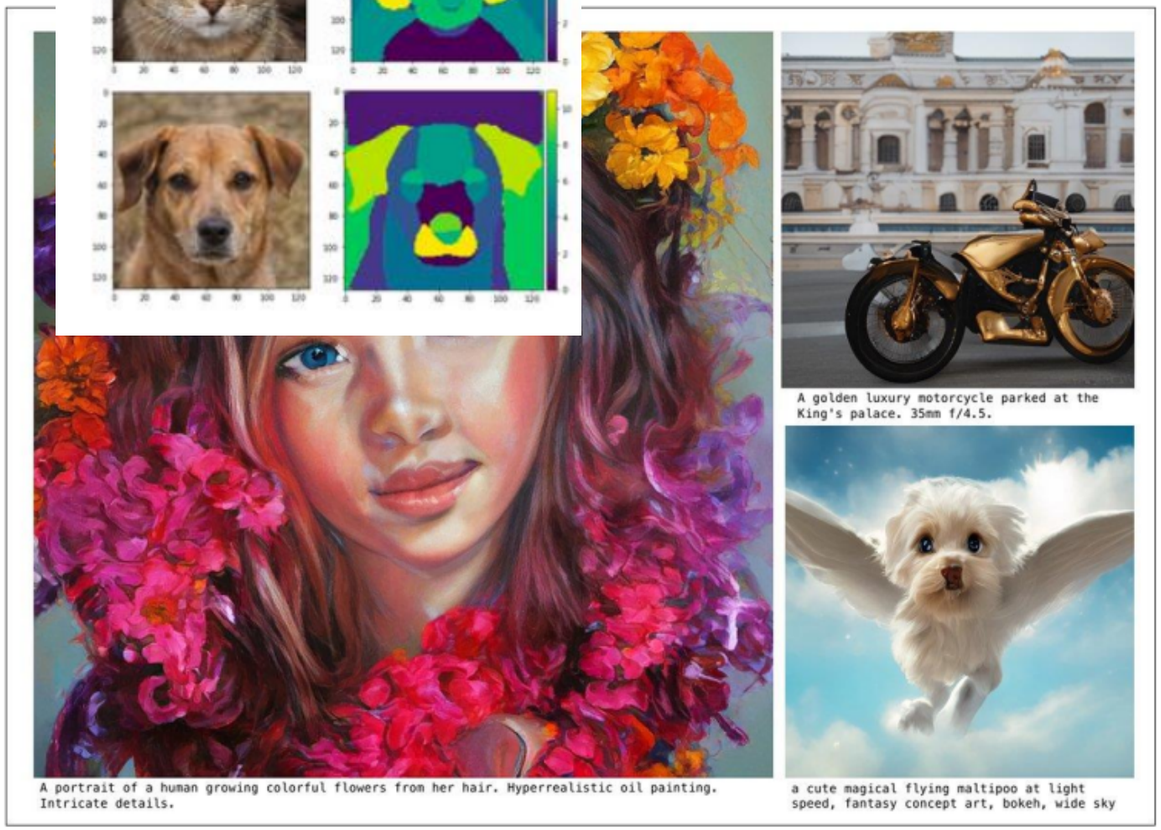


Aprendizado Não-Supervisionado

- Agrupamento
- Detecção de Anomalia
- Regras de Associação
- Redução de Dimensionalidade
- IA Generativa







Aprendizado Supervisionado: Regressão Linear

Regressão Linear

É um dos modelos mais comuns e simples.

Mas que ainda se mantém em uso! Justamente por sua simplicidade, interpretabilidade e consistência quando bem empregado em dados lineares.

Foi aprimorado para uso com regularizadores e otimizadores como gradiente de descida estocástico (SGD).

Regressão Linear

A análise de regressão estuda a relação entre uma variável chamada a variável dependente e outras variáveis chamadas variáveis independentes

A relação entre elas é representada por um modelo matemático, que associa a variável dependente com as variáveis independentes.

Regressão Linear

- O modelo inicial é designado por modelo de regressão linear simples (MRLS) pois apenas define uma relação linear entre a variável dependente e uma variável independente.

$$E(Y \mid X = x) = \beta_0 + \beta_1 x$$

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

$$\varepsilon \sim N(0, \sigma)$$



Gauss

Regressão Linear

- O modelo é designado por modelo de regressão linear simples (MRLS) quando define uma relação linear entre a variável dependente e uma variável independente.

$$E(Y \mid X = x) = \beta_0 + \beta_1 x$$

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

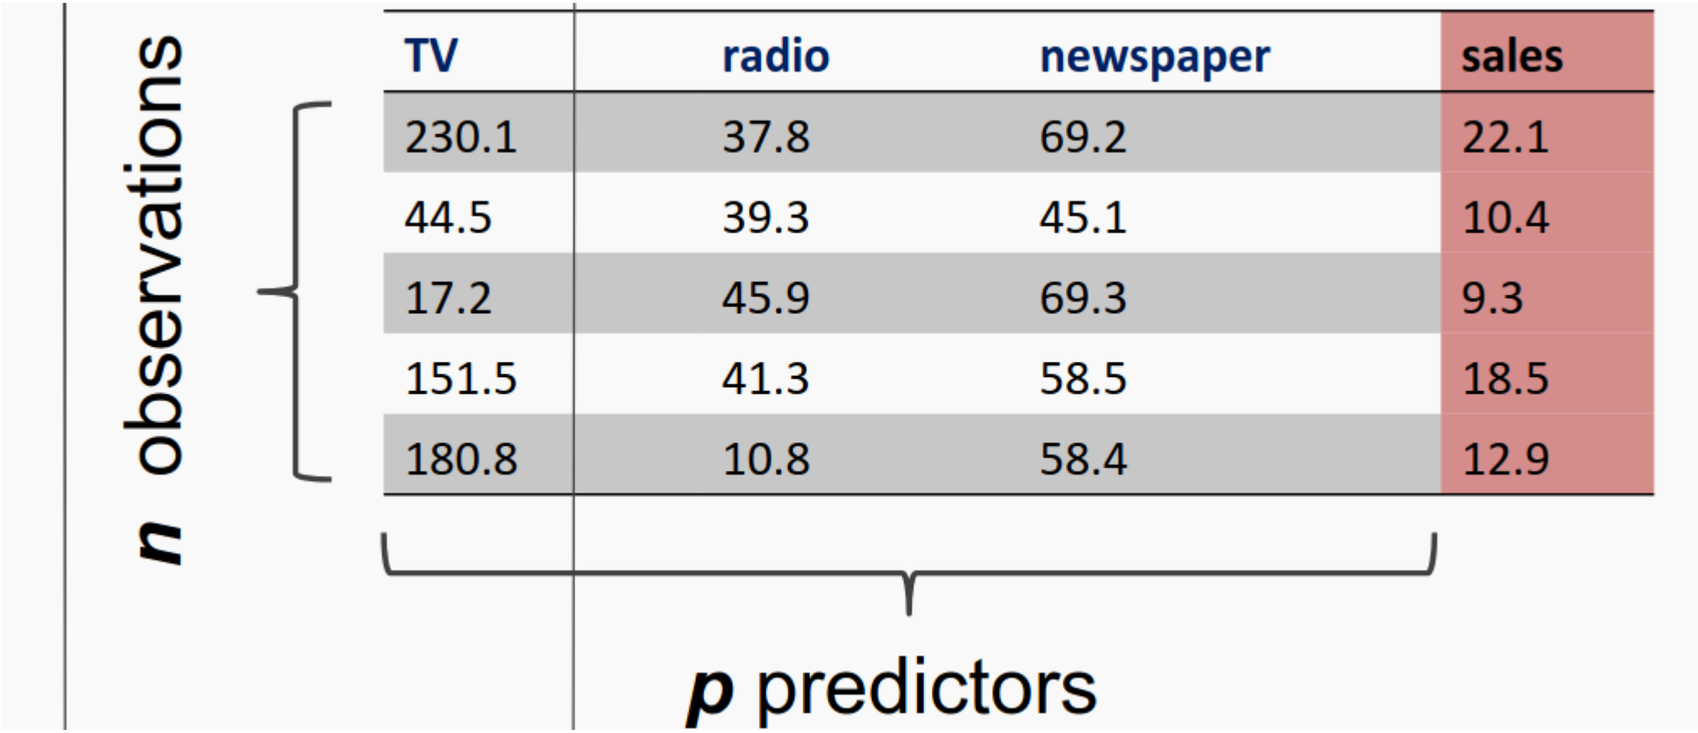
- Se em vez de uma, forem incorporadas várias variáveis independentes, o modelo passa a denominar-se modelo de regressão linear múltipla

$$Y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_{p-1} x_{i,p-1} + \varepsilon_i$$

Regressão Linear

X: atributos preditores

Y: resposta de saída (variável dependente)



TV	radio	newspaper	sales
230.1	37.8	69.2	22.1
44.5	39.3	45.1	10.4
17.2	45.9	69.3	9.3
151.5	41.3	58.5	18.5
180.8	10.8	58.4	12.9

Regressão Linear Simples

- Vamos começar com o modelo simples!

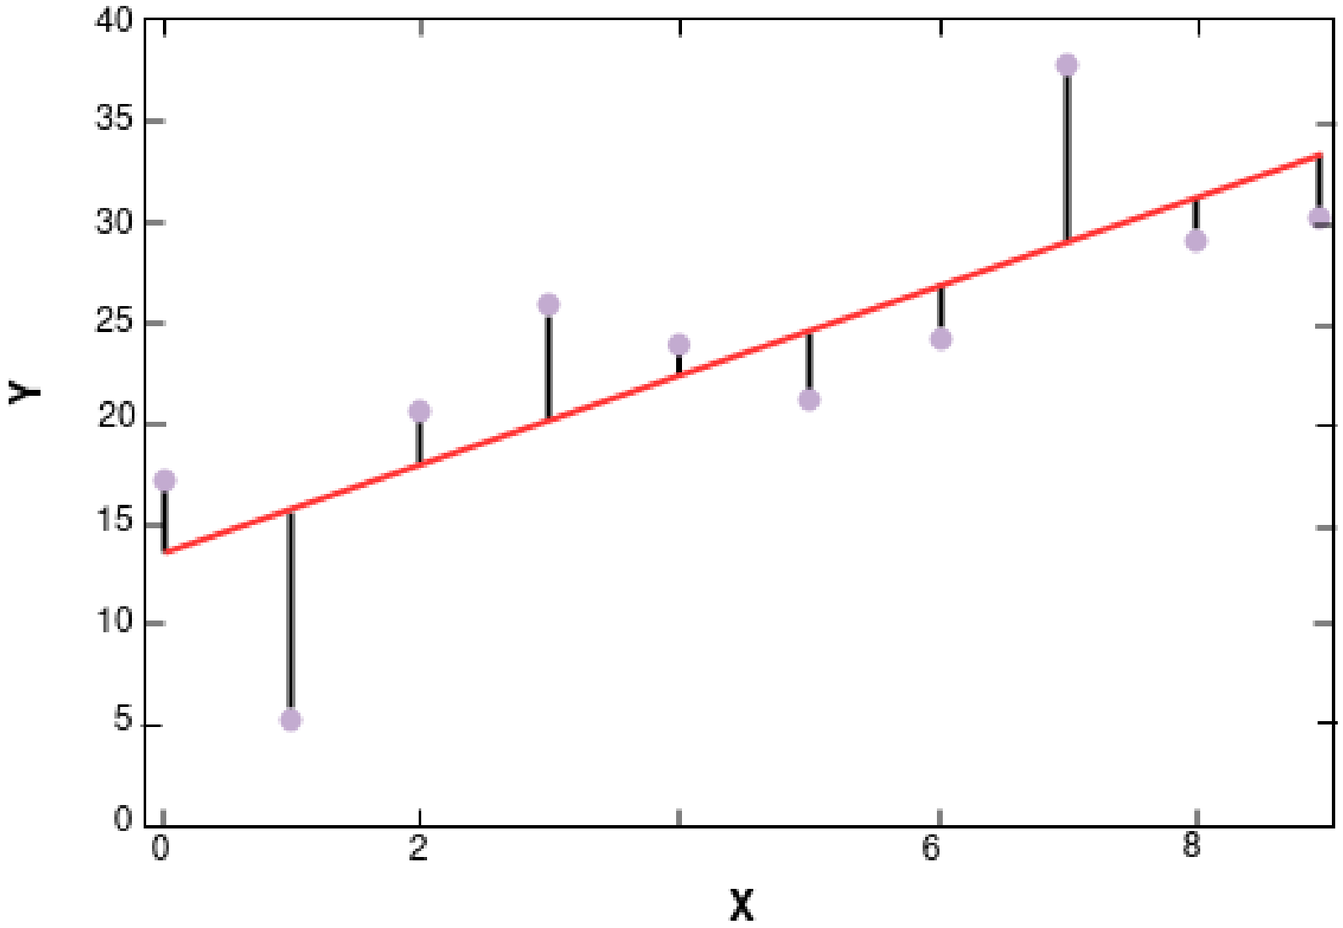
- No MRLS estudamos a relação linear entre duas variáveis quantitativas

Exemplos:

- Nível de ensino e renda;
- Altura dos pais e altura dos filhos;
- Renda semanal e despesas de consumo;
- Variação dos salários e taxa de desemprego;
- Demanda dos produtos de uma firma e publicidade.

Regressão Linear

Matematicamente, regressão linear se baseia em minimizar a soma do resíduo entre cada ponto e o valor predito.



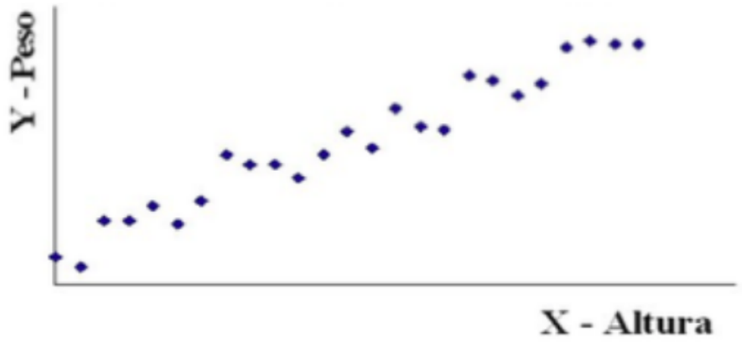
Fundamentos

- Podemos explicitar sob dois pontos de vista:
  - Explicitando a forma dessa relação: regressão
  - Quantificando a força ou o grau dessa relação: correlação

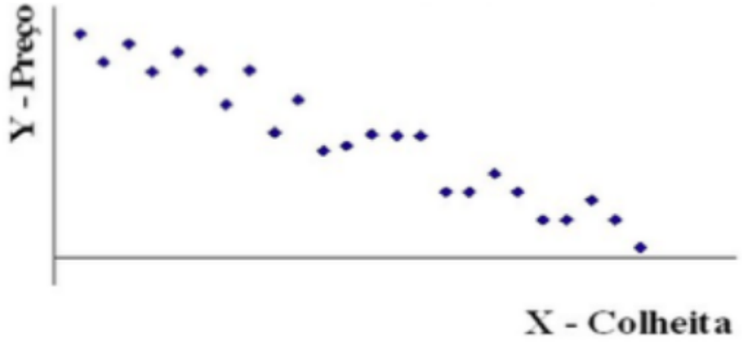
As técnicas de análise de correlação e regressão estão muito ligadas

Diagrama de dispersão

Diagramas que sugerem uma regressão linear entre as variáveis



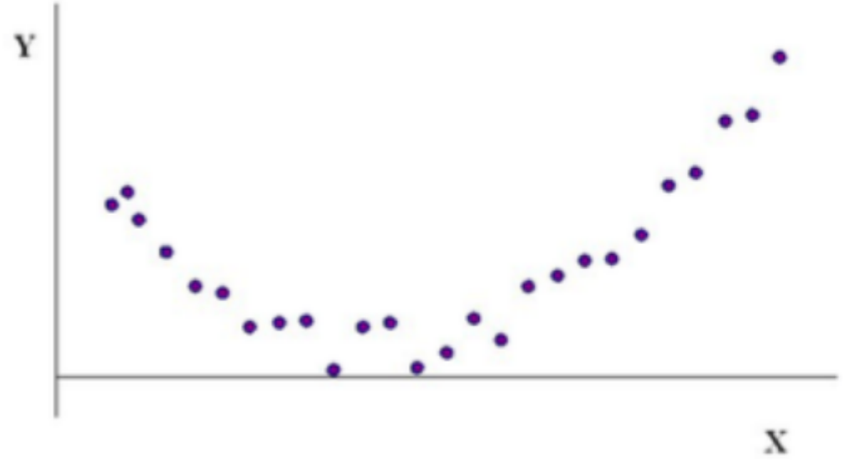
Existência de correlação positiva

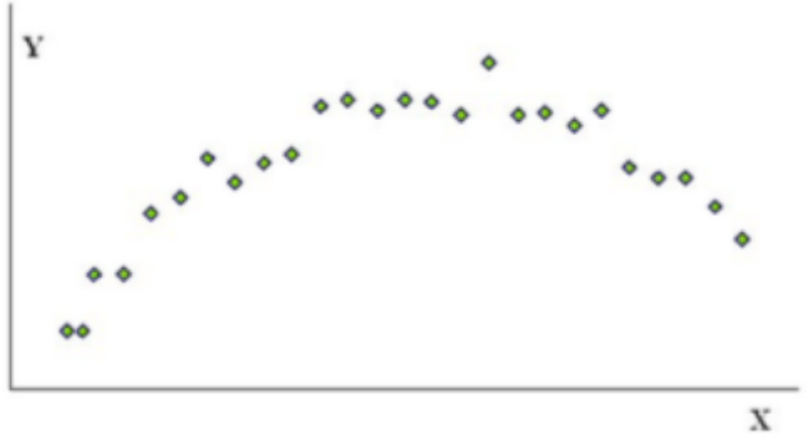


Existência de correlação negativa

Diagrama de dispersão

Diagramas que sugerem uma regressão não-linear entre as variáveis





NOTA: O termo "linear" é usado para indicar que o modelo é linear nos parâmetros da regressão **α** e **β**

$$E(Y|x) = \alpha + \beta x + \gamma x^2$$ ✅

$$E(Y|x) = \alpha e^{\beta x}$$ ❌

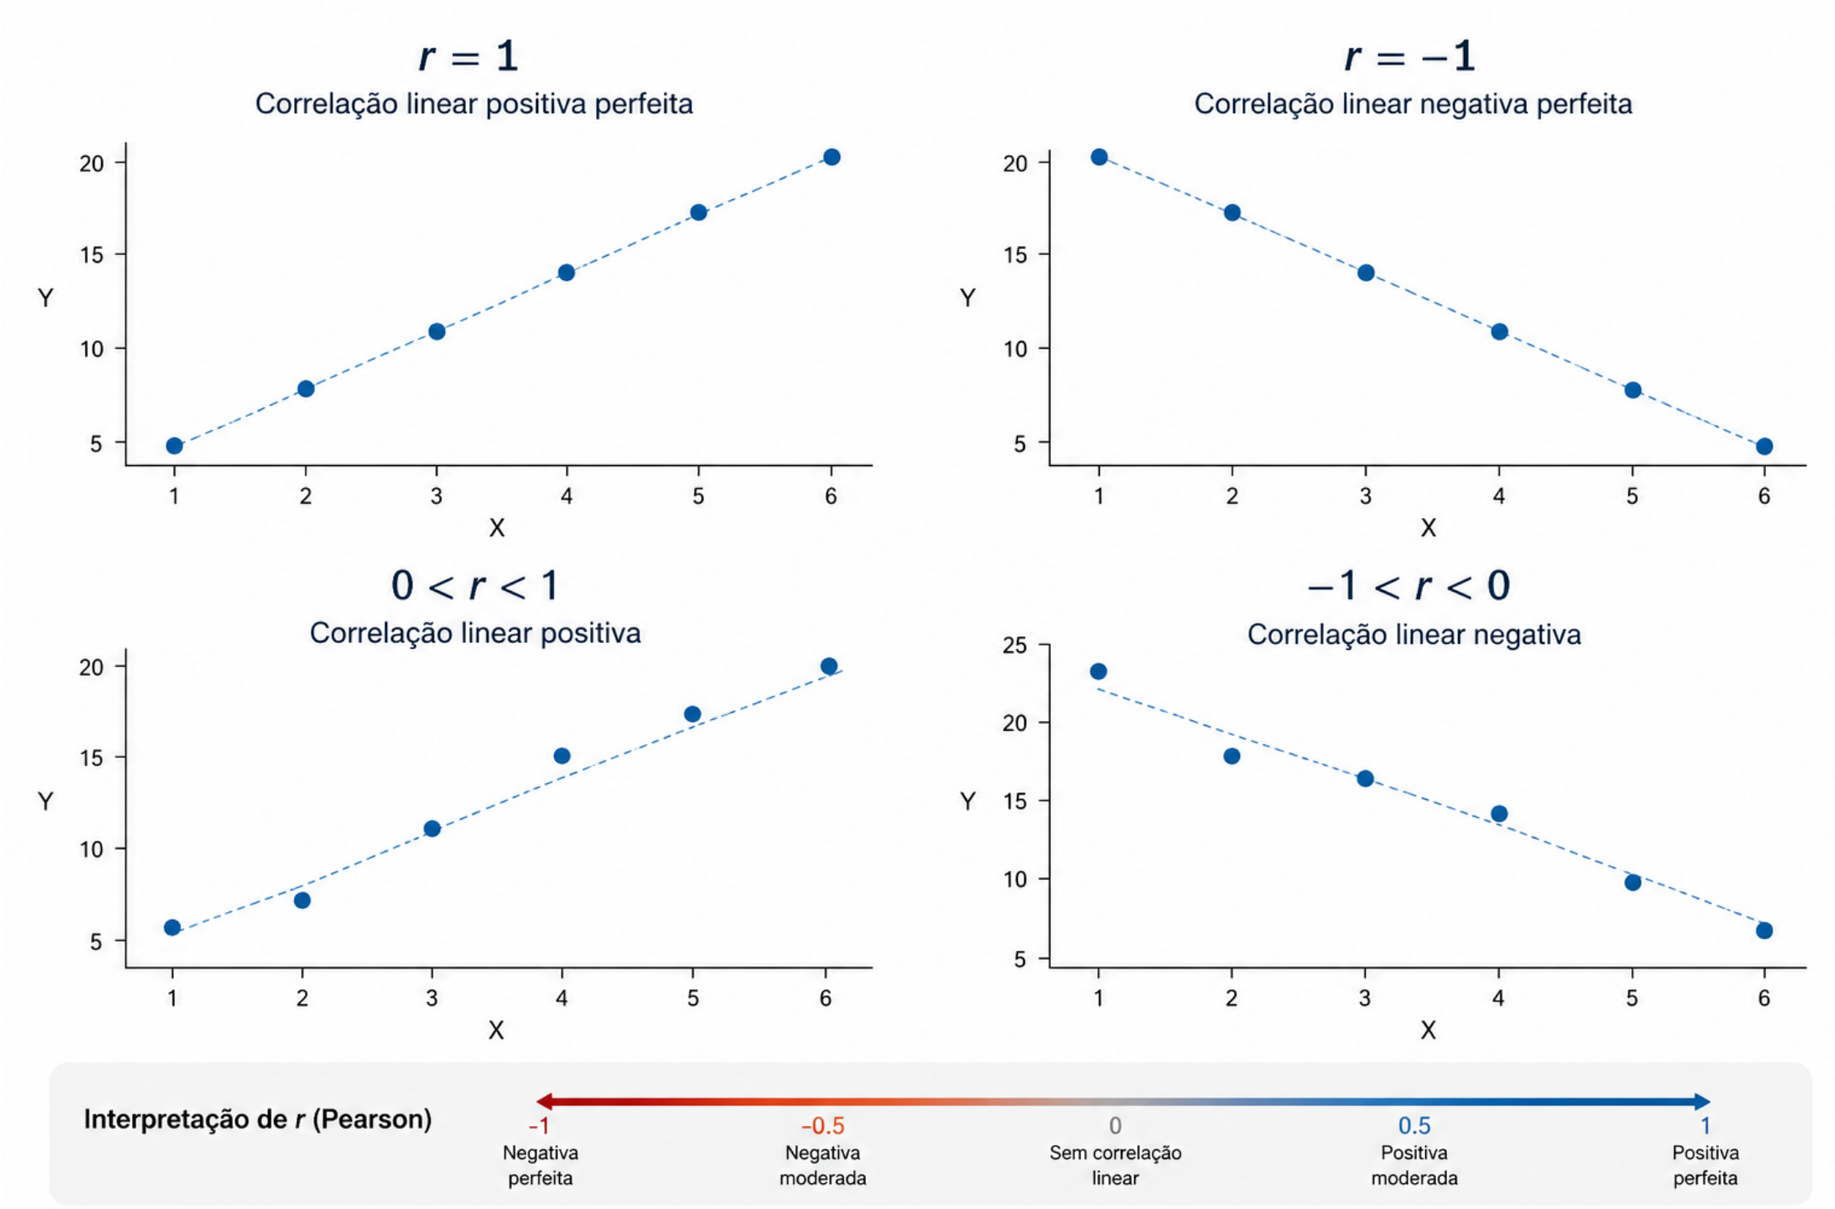
Coeficiente de correlação linear

Designamos de coeficiente de correlação linear

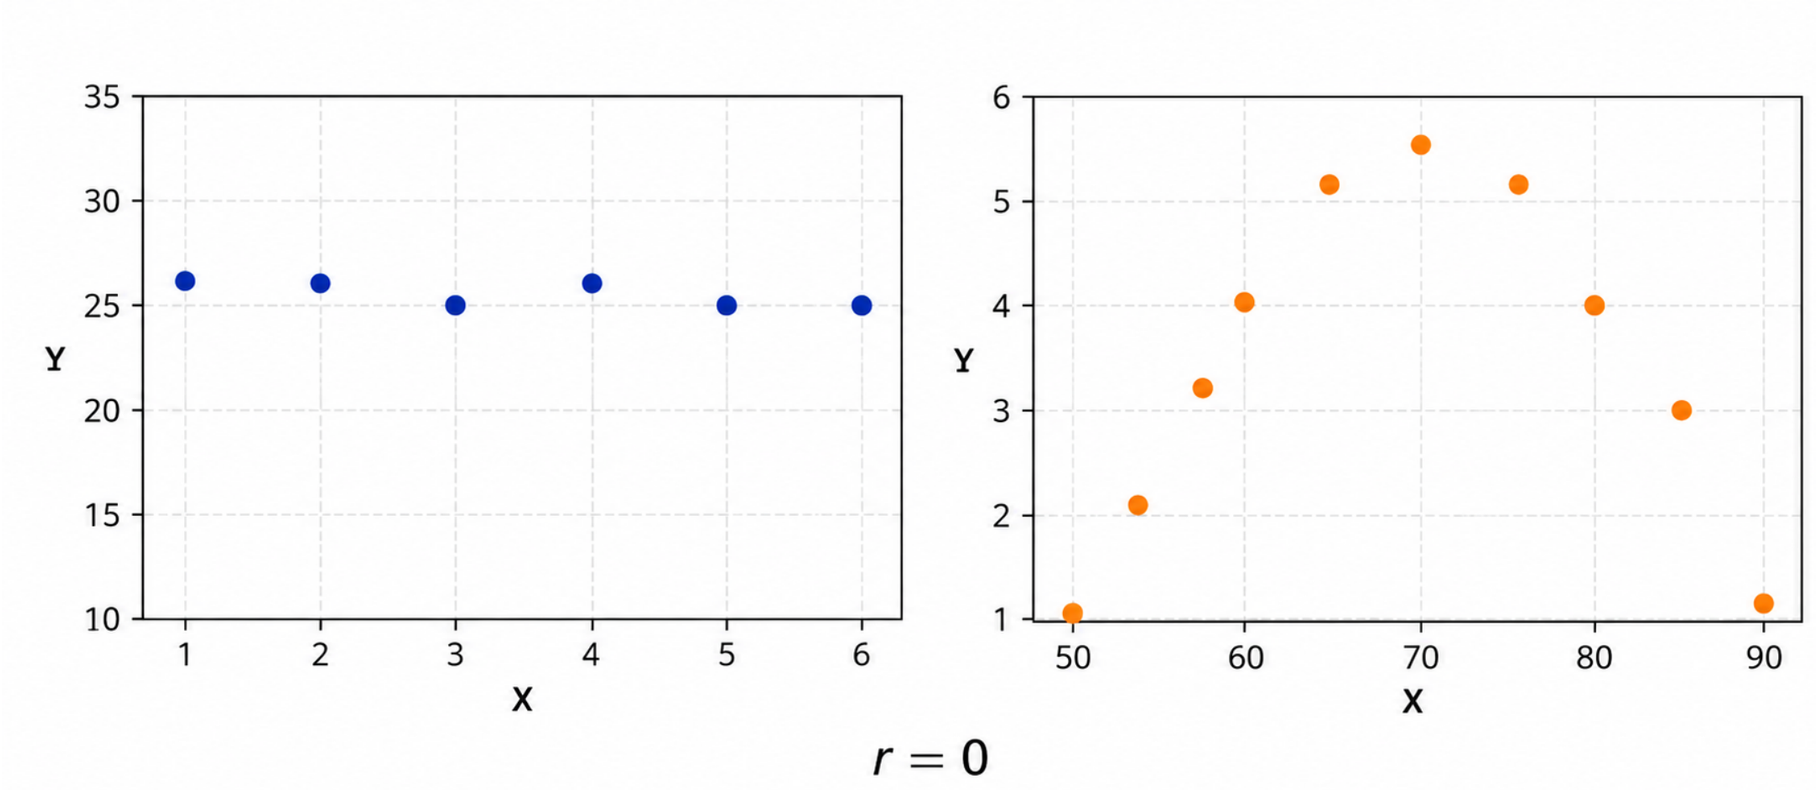
$$r = \frac{\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}}{\sqrt{\left(\sum_{i=1}^{n} x_i^2 - n\bar{x}^2\right)\left(\sum_{i=1}^{n} y_i^2 - n\bar{y}^2\right)}}$$

- $-1 \leq r \leq 1$;
- $r = 1$: relação linear perfeita (e positiva) entre X e Y;
- $r = 0$: inexistência de relação linear entre X e Y;
- $r = -1$: relação linear perfeita (e negativa) entre X e Y;
- $r > 0$: relação linear positiva entre X e Y;
- $r < 0$: relação linear negativa entre X e Y.

Coeficiente de correlação linear



Coeficiente de correlação linear

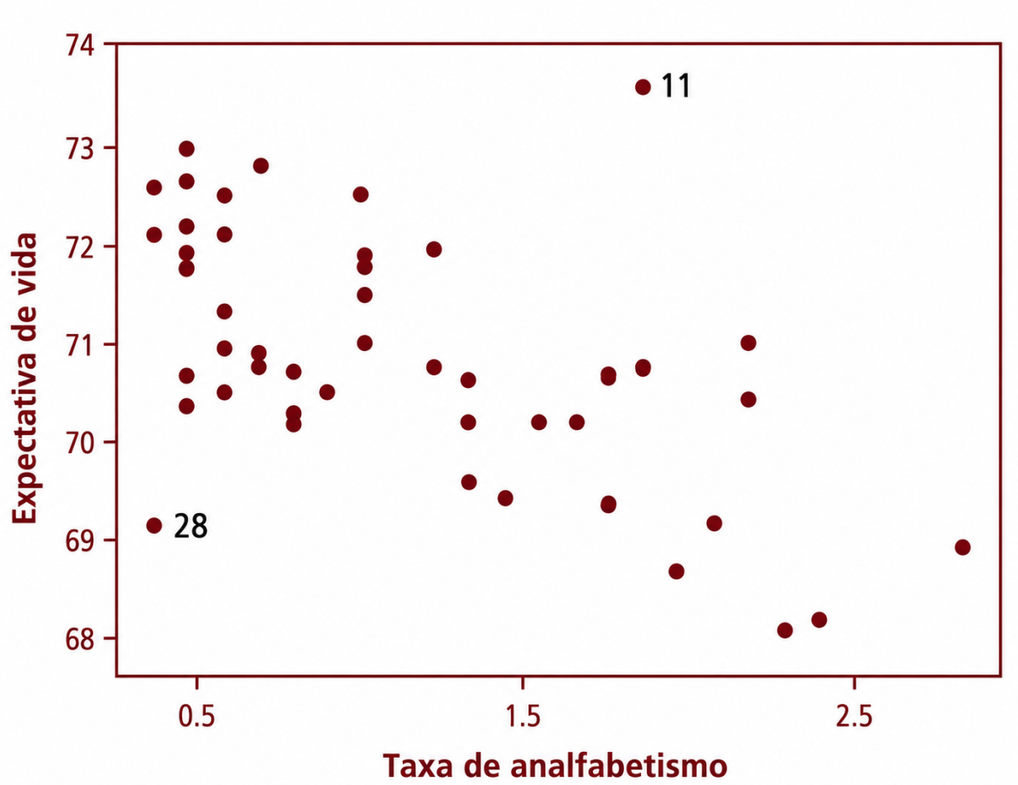


ATENÇÃO: Correlação zero não implica ausência de relação (apenas ausência de relação linear

Exemplo

Considere as duas variáveis abaixo observadas nos estados norte-americanos

Y: expectativa de vida
X: taxa de analfabetismo



Observações: Quanto maior é a taxa de analfabetismo, menor é a expectativa de vida; com sugestão de uma tendência linear entre as variáveis

Coeficiente de correlação linear

Exemplo: Calcule o coeficiente de correlação entre X e Y, sabendo que n=50:

$$\bar{y} = 70,88; \quad \bar{x} = 1,17; \quad \sum_{i=1}^{n} x_i y_i = 4122,8$$

$$\sum_{i=1}^{n} x_i^2 - n\bar{x}^2 = 88,247; \quad \sum_{i=1}^{n} y_i^2 - n\bar{y}^2 = 18,173$$

$$r = \frac{\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}}{\sqrt{\left(\sum_{i=1}^{n} x_i^2 - n\bar{x}^2\right)\left(\sum_{i=1}^{n} y_i^2 - n\bar{y}^2\right)}}$$

./data_correlacao.csv



Coeficiente de correlação linear

Exemplo: Calcule o coeficiente de correlação entre X e Y, sabendo que:

$$\overline{y} = 70,88; \quad \overline{x} = 1,17; \quad \sum_{i=1}^{n} x_i y_i = 4122,8$$

$$\sum_{i=1}^{n} x_i^2 - n\bar{x}^2 = 88,247; \quad \sum_{i=1}^{n} y_i^2 - n\bar{y}^2 = 18,173$$

$$r = \frac{4122,8 - 50 \times 1,17 \times 70,88}{\sqrt{88,247 \times 18,173}} = \frac{-23,68}{40,047} = -0,59$$

MRLS

$$Y = E(Y|X = x) + \epsilon = \alpha + \beta x + \epsilon$$

Y - variável explicada ou dependente (aleatória)

X - variável explicativa ou independente medida sem erro (não aleatória)

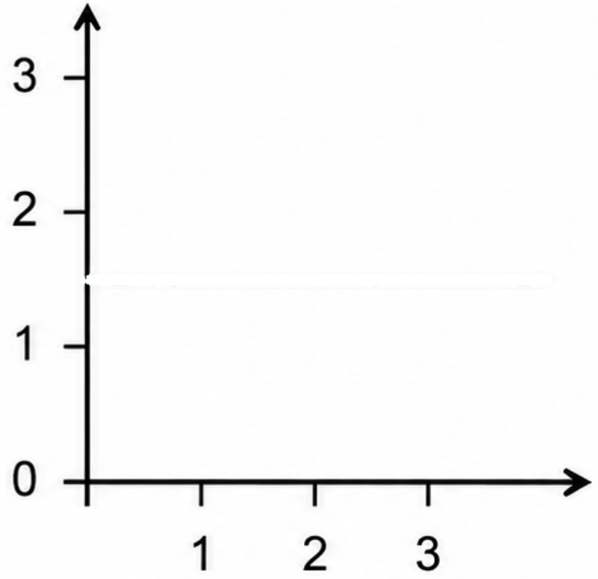
α - coeficiente de regressão, que representa o intercepto (parâmetro desconhecido do modelo -> a estimar)

β - coeficiente de regressão, que representa o declive (inclinação) (parâmetro desconhecido do modelo -> a estimar)

ϵ - erro aleatório ou estocástico, onde se procuram incluir todas as influências no comportamento da variável Y que não podem ser explicadas linearmente pelo comportamento da variável X;

Entendendo os parâmetros

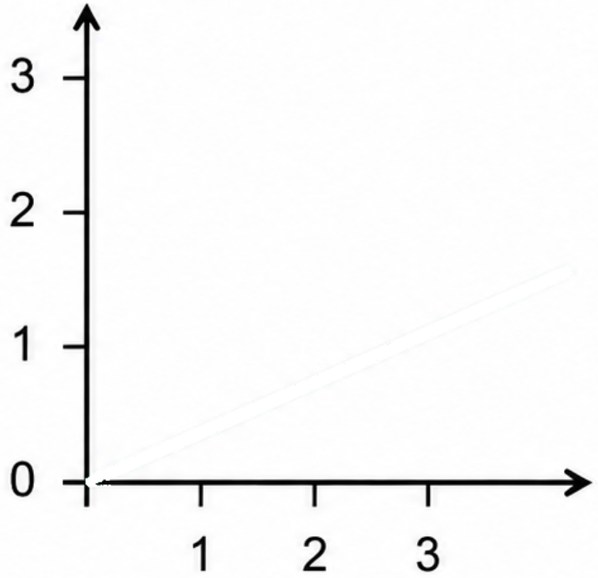
$h(x) = 1.5 + 0x$



$\theta_0 = 1.5$

$\theta_1 = 0$

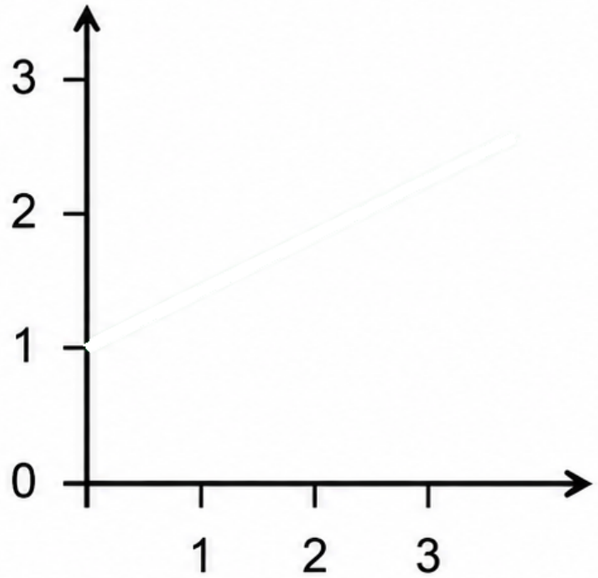
$h(x) = 0 + 0.5x$



$\theta_0 = 0$

$\theta_1 = 0.5$

$h(x) = 1 + 0.5x$

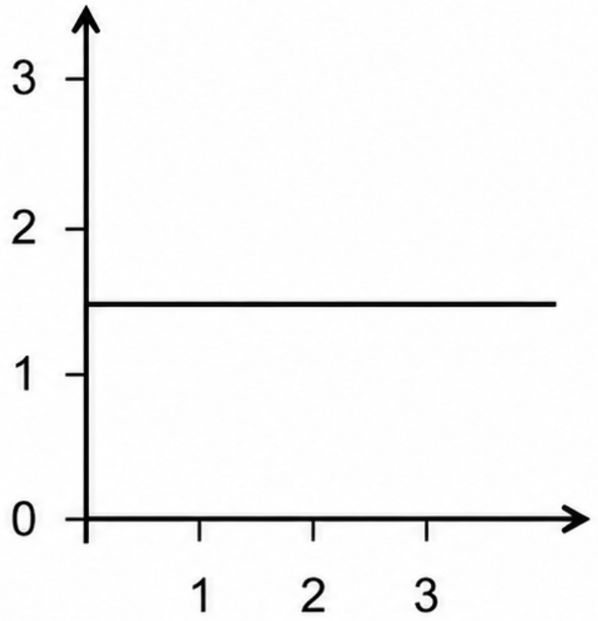


$\theta_0 = 1$

$\theta_1 = 0.5$

Entendendo os parâmetros

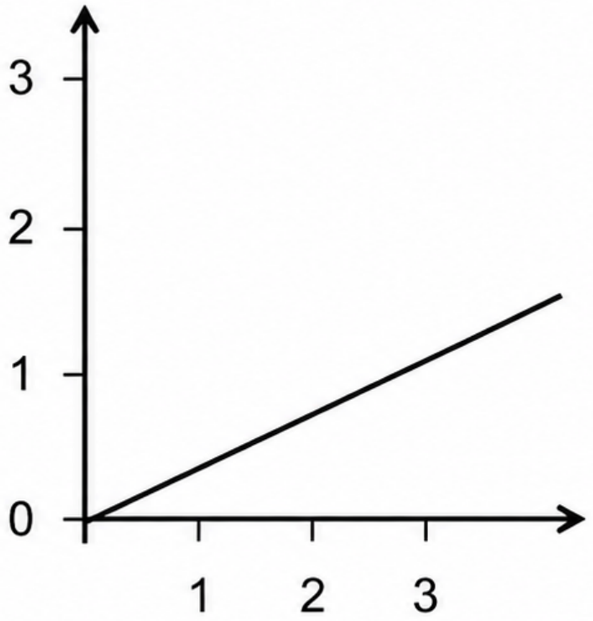
$h(x) = 1.5 + 0x$



$\theta_0 = 1.5$

$\theta_1 = 0$

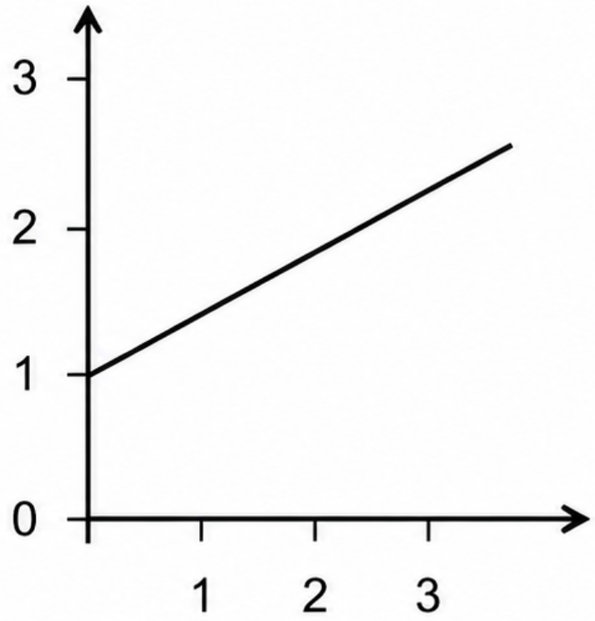
$h(x) = 0 + 0.5x$



$\theta_0 = 0$

$\theta_1 = 0.5$

$h(x) = 1 + 0.5x$



$\theta_0 = 1$

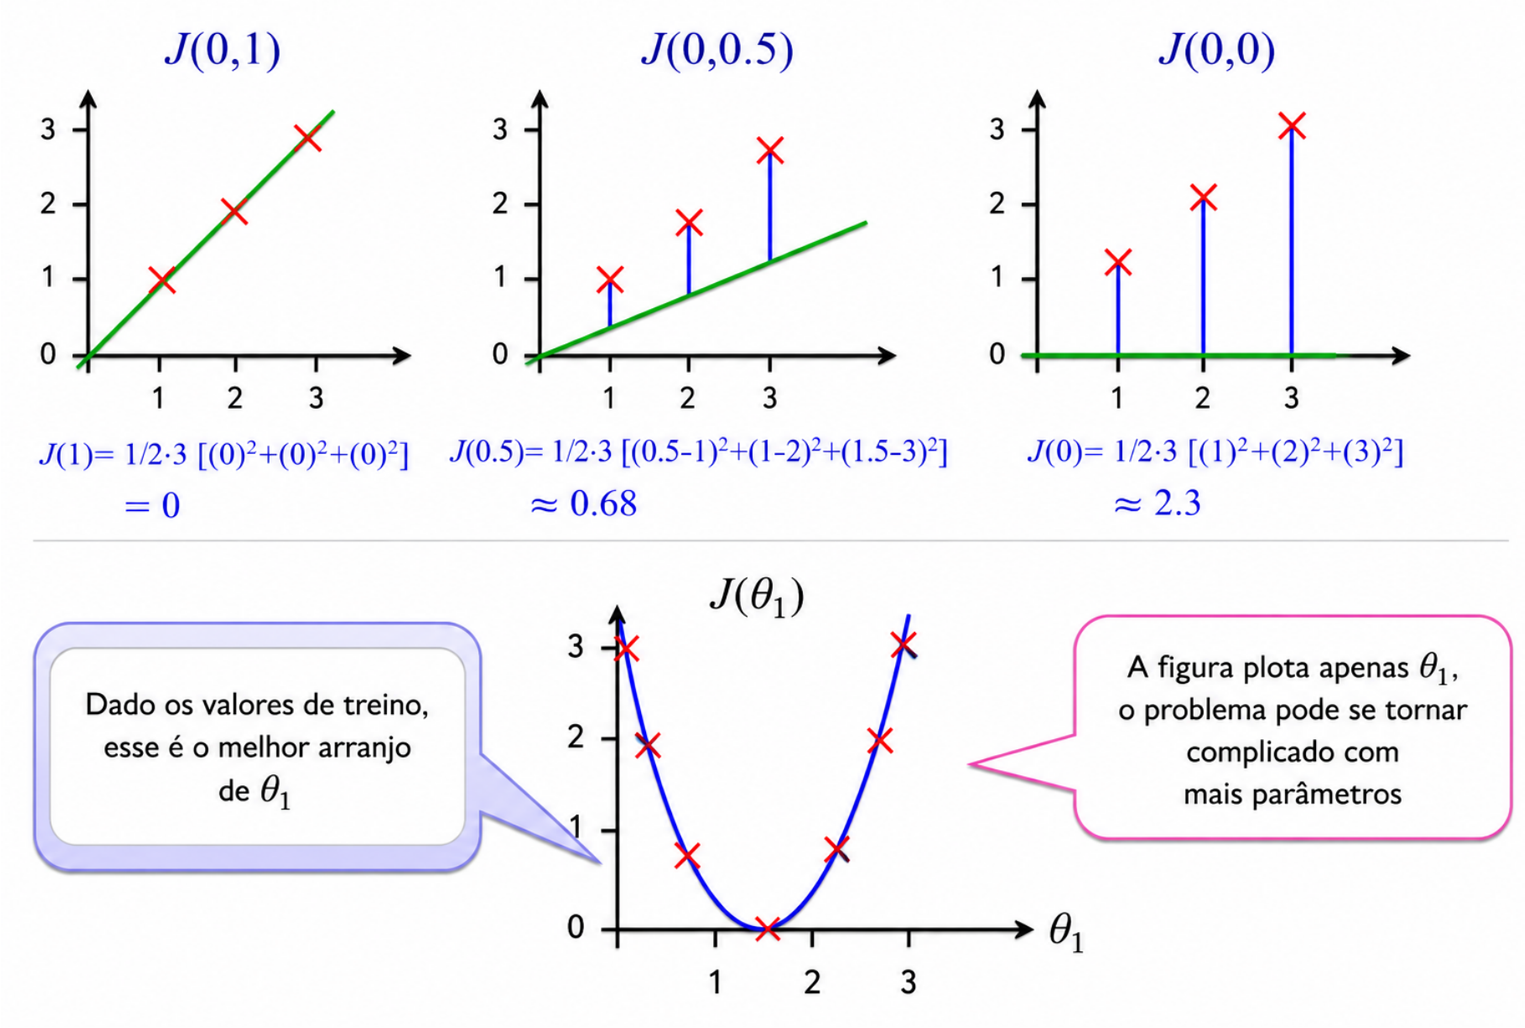
$\theta_1 = 0.5$

Parâmetros

Uma função custo (ou objetivo) buscará por uma solução que minimize o erro do modelo. Ideia: obter valores de parâmetros que permitam um modelo que mais se aproxime dos valores reais (supervisionado).

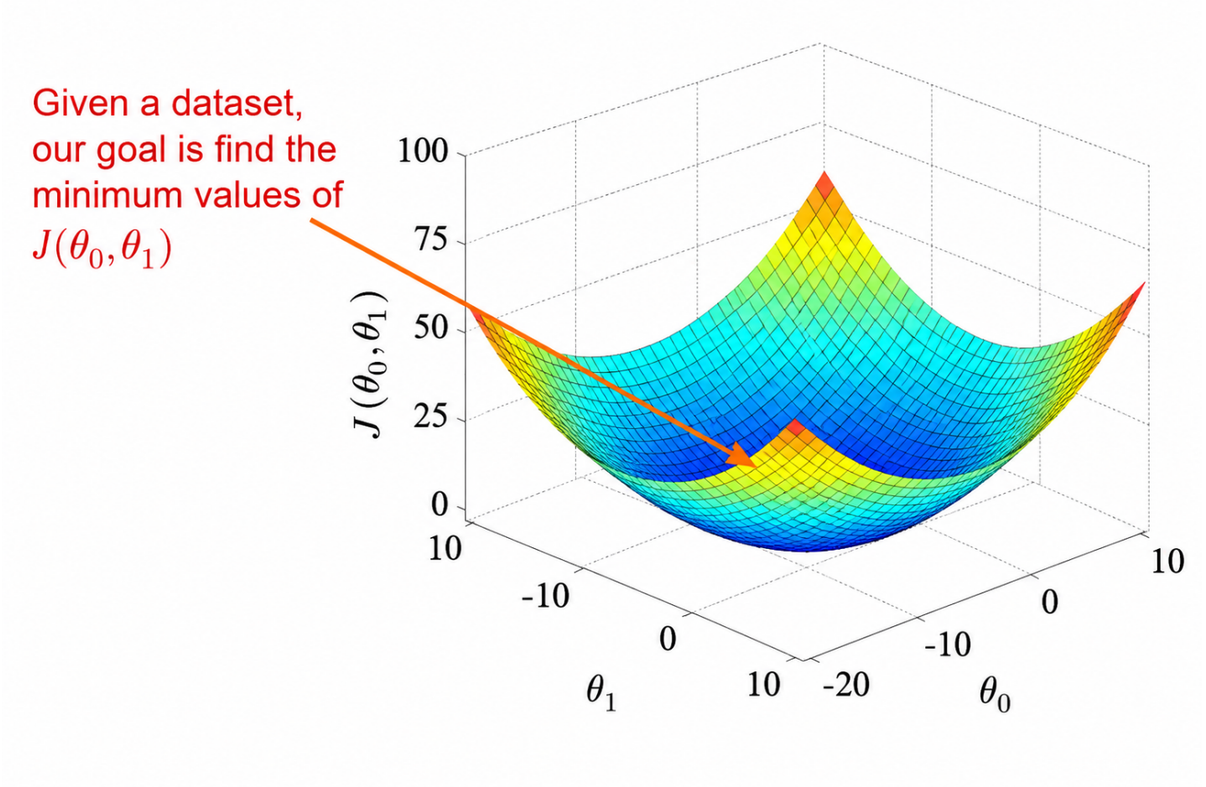
$$J(\beta) = \frac{1}{m}\sum_{i=1}^{m}(y_i - f(x_i))^2$$

Função Custo (Objetivo)



Função Custo (Objetivo)

Dado um *dataset*, nossa meta é obter um valor mínimo para a função



Função Custo (Objetivo)

“Derivamos a função de erro em relação aos parâmetros porque queremos encontrar o ponto em que pequenas alterações nesses parâmetros não conseguem mais reduzir o erro”

Como temos dois parâmetros, obtemos duas equações, cuja solução fornece a reta de menor erro



Exemplo de solução MMQ (OLS)

